本科毕业论文（设计）

基于自适应压缩感知与状态空间模型的超声图像增强方法

AN ULTRASOUND IMAGE ENHANCEMENT METHOD BASED ON ADAPTIVE COMPRESSED SENSING AND STATE SPACE MODEL

高浚博

哈尔滨工业大学

2026 年 6 月

☑ 毕业论文　☐ 毕业设计　　密级：公开

本科毕业论文（设计）

基于自适应压缩感知与状态空间模型的超声图像增强方法

本　　科　　生：高浚博

学　　号：2022111114

指　导　教　师：陈逸飞

专　　业：自动化

学　　院：航天学院

答　辩　日　期：2026 年 5 月

学　　校：哈尔滨工业大学

摘　要

医学超声图像具有实时、无电离辐射、成本较低和便于床旁检查等优势，但受组织散射、波束线数、成像深度和系统带宽等因素影响，常出现散斑噪声明显、组织边界模糊、弱小目标显示不足和空间分辨率受限等问题。针对噪声抑制、结构保持与分辨率提升难以兼顾的问题，本文研究基于自适应压缩感知与状态空间模型的超声图像增强方法。

首先，提出基于高效视频编码块划分的结构先验提取方法，通过限制帧内预测模式、重构率失真成本并自适应调整量化清零阈值，使组织边界、亮点目标和高频纹理区域形成更细粒度划分。亮斑组实验中，感兴趣区域内变换单元平均大小由6.3321 降至 4.6001，背景区域与感兴趣区域之比由 0.8940 升至 1.0091，表明改进后的块划分增强了结构区分能力。

其次，提出结构先验引导的自适应分块 K-SVD 去噪方法，并将其命名为 Block K-SVD。该方法将块划分结果转化为像素级尺度图，并通过插值、灰度调节、离散聚类和多字典稀疏重建实现差异化去噪。Block K-SVD 的对比度噪声比和等效视数较原始图像分别提高 2.36%和 4.83%；相较固定 8×8 分块方法，边缘保持指数和特征相似性指数分别提高 6.98%和 5.26%，且较遍历 6 种固定块大小的总耗时缩短 18.72%。

最后，构建面向医学超声 B 模式图像超分辨率的 USR-Mamba 网络，通过空间—频率双域状态空间建模、残差卷积和角向均匀扫描增强局部细节与长距离上下文表达。以 Block K-SVD 32 线去噪图像为输入时，输出图像的对比度噪声比由 1.8058 提高至 1.8249，学习感知图像块相似度由 0.1800 降至 0.1481，亮点组水平半高全宽由 40.9381 降至 19.8342，与原生 128 波束线数参考图像的 20.7405 接近。

关键词：超声图像增强；结构先验；压缩感知；状态空间模型；USR-Mamba

Abstract

Medical ultrasound imaging is real-time, non-ionizing, inexpensive, and suitable for bedside use, but tissue scattering, beamline count, imaging depth, and system bandwidth can cause speckle, blurred boundaries, weak-target loss, and limited spatial resolution. This thesis studies ultrasound image enhancement based on adaptive compressed sensing and state space models to balance noise suppression, structural preservation, and resolution improvement.

First, structural priors are extracted from High Efficiency Video Coding (HEVC) block partitions by restricting intra-prediction modes, reformulating the rate-distortion cost, and adapting the quantization zeroing threshold to refine boundaries, bright targets, and high-frequency textures. In the bright-spot group, mean transform-unit size in regions of interest decreases from 6.3321 to 4.6001, and the background-to-region ratio rises from 0.8940 to 1.0091, indicating better discrimination.

Second, the structural-prior-guided Block K-SVD denoiser converts partitions into a pixel-wise scale map and combines interpolation, grayscale adjustment, clustering, and multi-dictionary sparse reconstruction for differentiated denoising. Its contrast-to-noise ratio and equivalent number of looks exceed the original images by 2.36% and 4.83%. Versus fixed 8×8 blocks, edge preservation and feature similarity improve by 6.98% and 5.26%, while runtime is 18.72% lower than processing six fixed sizes.

Finally, USR-Mamba combines dual-domain state space modeling, residual convolution, and angular-uniform scanning for B-mode super-resolution. With denoised 32-beamline inputs, its contrast-to-noise ratio rises from 1.8058 to 1.8249, Learned Perceptual Image Patch Similarity falls from 0.1800 to 0.1481, and bright-point horizontal full width at half maximum decreases from 40.9381 to 19.8342, near 20.7405 for native 128-beamline references.

Keywords: ultrasound image enhancement, structural prior, compressed sensing, state space model, USR-Mamba

目　录

摘　要 I
Abstract II
第 1 章 绪　论 1
1.1 课题背景及研究的目的和意义 1
1.2 国内外相关研究现状分析 3
1.2.1 压缩感知在图像增强中的应用 3
1.2.2 深度学习在图像增强中的应用 4
1.2.3 超声图像增强研究现状 5
1.3 本文的主要研究内容 6
第 2 章 基于 HEVC 块划分的超声图像结构先验信息提取方法 9
2.1 引言 9
2.2 面向自然图像保真压缩的 HEVC 块划分方法 9
2.2.1 多层级分块 11
2.2.2 帧内预测 12
2.2.3 变换与量化 13
2.2.4 编码决策 14
2.3 面向超声结构先验提取的 HEVC 块划分方法 15
2.3.1 结构先验提取目标导向 HEVC 流程优化 15
2.3.2 基于动态权重的率失真成本目标函数设计 16
2.3.3 基于动态清零阈值的率失真优化量化方法 17
2.4 评价指标与结果分析 18
2.5 本章小结 23
第 3 章 基于结构先验信息的自适应分块压缩感知去噪方法 24
3.1 引言 24
3.2 基于 K-SVD 与 OMP 的字典迭代学习去噪方法 24
3.3 基于 HEVC 块划分的自适应压缩感知去噪方法 27
3.3.1 基于 TU 中心点的块大小插值 28
3.3.2 基于 PU 灰度的分块放大 29
3.3.3 平滑滤波与离散聚类 29

3.3.4 多字典融合去噪 31
3.4 评价指标与结果分析 33
3.4.1 评价指标 33
3.4.2 结果分析 35
3.5 本章小结 40
第 4 章 超声超分辨率成像 USR-Mamba 网络研究 41
4.1 引言 41
4.2 超声超分辨率成像 USR-Mamba 网络设计 41
4.2.1 基于双域 SSM 的超分辨率网络架构 43
4.2.2 基于残差 CNN 的空间细节优化方法 45
4.2.3 基于角向均匀扫描的序列展开方法 47
4.3 数据集预处理与消融实验设计 48
4.3.1 数据集预处理 49
4.3.2 消融实验设计 50
4.4 评价指标与结果分析 51
4.4.1 评价指标 51
4.4.2 结果分析 52
4.5 本章小结 60
结 论 61
参考文献 62
哈尔滨工业大学本科毕业论文（设计）原创性声明与使用权限 65
致 谢 66

第 1 章　绪　论

1.1　课题背景及研究的目的和意义

医学影像技术是现代临床诊疗体系的重要组成部分，可用于显示人体组织和器官的形态结构及生理功能状态，并为疾病的诊断、治疗和管理提供依据[1]。不同医学影像模态在临床中承担不同功能：计算机断层成像（Computed Tomography，CT）主要用于高密度组织和解剖结构显示，磁共振成像（Magnetic Resonance Imaging，MRI）侧重软组织成像和多参数评估，正电子发射断层成像（Positron Emission Tomography，PET）侧重代谢和功能信息；医学超声具有实时成像、无电离辐射、设备成本较低和便于床旁检查等特点，广泛用于动态观察、快速筛查和介入引导。医学影像在临床诊疗流程中的作用如图 1-1 所示。

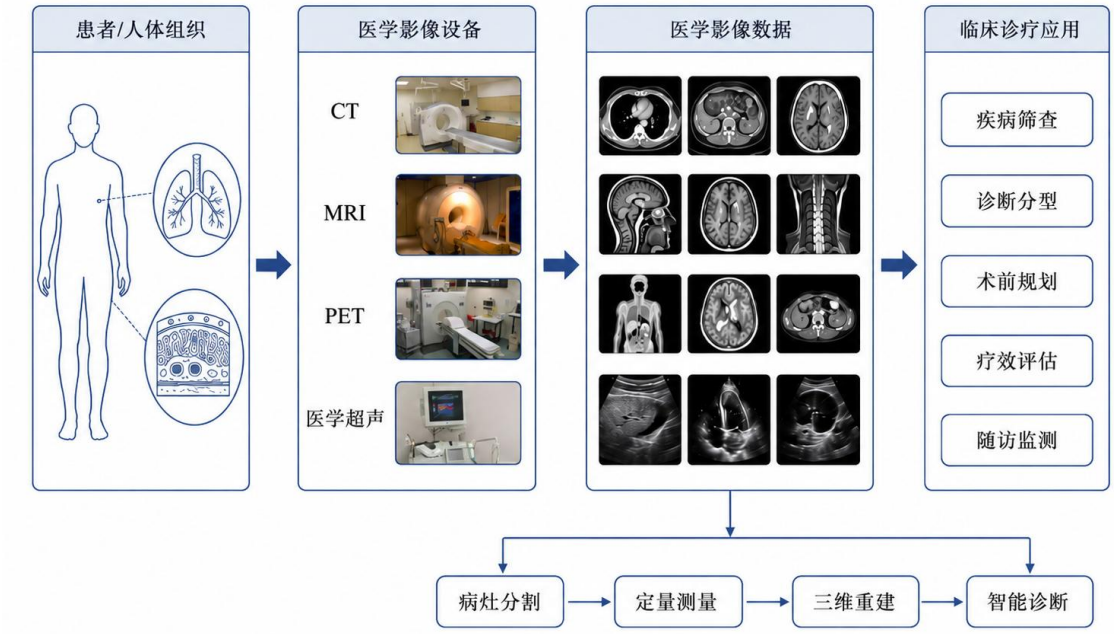


图 1-1　医学影像技术在临床诊疗流程中的作用

医学超声利用声波与组织相互作用形成图像，具有实时、无电离辐射和成本较低等特点，在甲状腺、乳腺、心脏及妇产科等临床检查中具有广泛应用价值[2]。与 CT 和 MRI 相比，超声图像的获取过程更依赖声束发射、回波接收、波束合成和后续信号处理，图像质量易受组织声学特性、探头频率、波束线数、成像深度和操作

者经验等因素影响。尤其是在弱回声区域、组织边界和小尺度亮点目标附近，超声图像常存在散斑噪声明显、边界模糊、对比度不足和空间分辨率受限等问题。提高超声图像清晰度和分辨率，有助于改善病灶边界识别、弱小目标观察和定量测量的可靠性，是超声图像增强研究的重要方向。

超声散斑噪声是影响超声图像质量的主要因素之一。由于一个分辨单元内部通常包含大量尺寸小于声波波长的散射体，这些散射体产生的回波在接收端发生相干叠加，从而形成明暗随机分布的散斑纹理。超声散斑噪声的形成过程及其对图像质量的影响如图 1-2 所示。散斑噪声通常表现为乘性噪声或局部相关噪声，会降低图像对比度和边缘清晰度，使病灶边界、细小结构和弱回声区域识别难度增加[3]。散斑并非不含有效信息的随机扰动，其在一定程度上反映了组织微观散射特性。因此，若在去噪过程中无差别平滑高频成分，虽然可以降低图像颗粒感，但也可能削弱真实组织边界和纹理细节，进而影响临床阅片和后续自动分析任务。

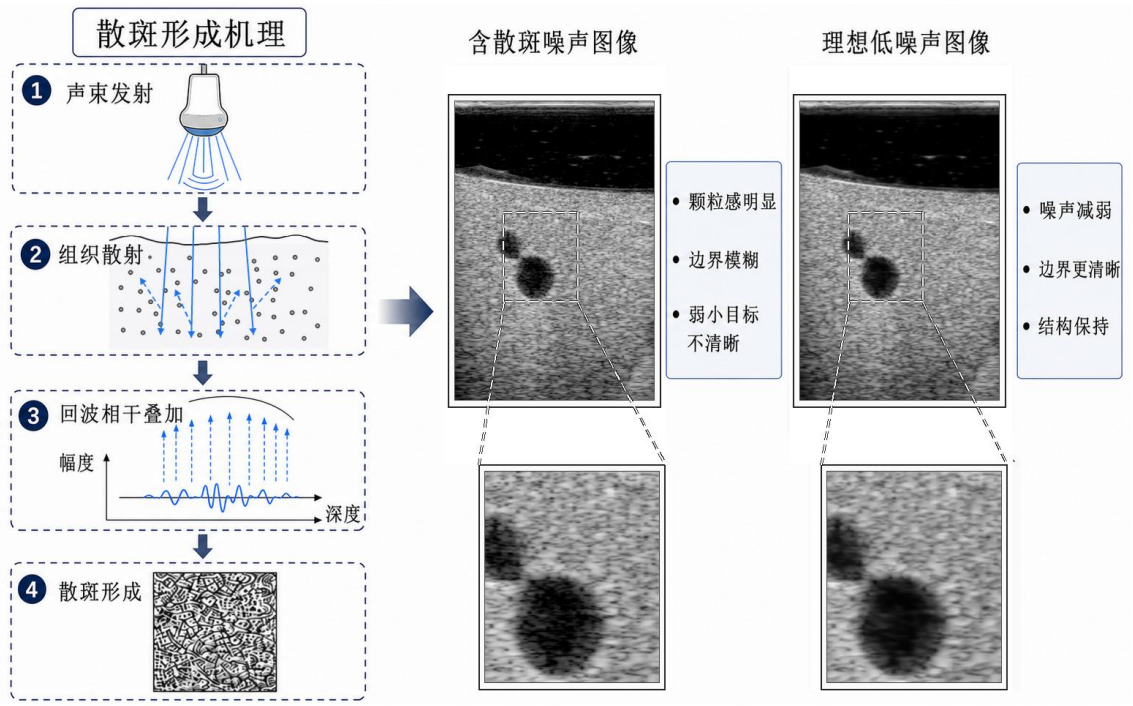


图 1-2　超声散斑噪声的形成及其影响

超声图像增强的目标是在不改变真实组织结构的前提下改善图像可读性和可分析性。根据增强对象的不同，常见任务主要包括超声图像去噪和超声图像超分辨率。前者重点抑制散斑噪声，并提高局部对比度和均匀区域稳定性；后者则旨在从低分辨率观测中恢复更清晰的组织边界、亮点目标和细纹理结构。二者虽然任务形

式不同，但本质上均需要处理噪声抑制与结构保持之间的矛盾：若增强强度不足，噪声和模糊仍会保留；若增强强度过高，则可能导致结构丢失、边缘过锐化或伪纹理生成。因此，面向超声图像的增强方法需要充分考虑局部结构复杂度，而不宜仅依赖统一的全局处理策略。

基于上述特点，研究从可解释结构先验和长距离序列建模两个方向展开：前者用于指导不同结构区域采用差异化去噪尺度，后者用于恢复低波束线数图像中的组织轮廓、散斑纹理和亮点空间响应。整体技术路线为结构先验提取—自适应压缩感知去噪—状态空间超分辨率增强。

1.2 国内外相关研究现状分析

1.2.1 压缩感知在图像增强中的应用

压缩感知（Compressed Sensing，CS）理论由 Donoho 以及 Candès 等学者提出，其基本思想是：若信号在某一基或字典下具有稀疏性或可压缩性，则可通过少量非自适应线性观测恢复原始信号[4,5]。该理论突破了传统采样定理对采样频率的严格要求，将信号采集、压缩和重建纳入统一框架，为欠采样条件下的信号恢复提供了新的理论基础。对于图像增强任务而言，图像虽然在空间域通常并不严格稀疏，但在离散余弦变换（Discrete Cosine Transform，DCT）、小波、梯度域或过完备字典上通常具有较强的可压缩性。因此，研究者将压缩感知与稀疏表示方法引入图像去噪、修复、压缩和超分辨率等问题，通过稀疏先验限制解空间，抑制不稳定解和噪声放大现象，从而在噪声扰动和采样不足条件下恢复更稳定的图像结构，并提升重建过程的约束性和可解释性。

在图像去噪中，基于稀疏表示的压缩感知方法已形成较成熟的研究体系。Aharon 等提出 K-奇异值分解（K-Singular Value Decomposition，K-SVD）字典学习方法，通过交替执行稀疏编码和字典更新，获得适应样本统计特性的过完备字典[6]；Elad 等进一步将 K-SVD 用于图像去噪，表明基于学习字典的稀疏表示能够有效抑制加性高斯噪声[7]。这类方法通常以重叠图像块为基本处理单元，并通过正交匹配追踪（Orthogonal Matching Pursuit，OMP）等贪婪算法求解稀疏系数，最后将重建图像块加权融合为完整图像，以减弱块边界不连续带来的视觉影响。其优势在于模型可解释性较强、局部细节恢复能力较好，且能够根据训练样本学习更贴合图像内容的表示基，从而提高局部结构表达能力；但由于通常采用固定块大小、固定字典

或固定稀疏约束，面对局部结构差异较大的图像时，容易出现背景平滑与细节保持之间的尺度折中。

在图像重建和超分辨率任务中，压缩感知方法通常将观测模型、稀疏先验和优化求解结合起来，从低采样率观测或低分辨率图像中恢复高质量图像。相关方法可利用小波、DCT、梯度稀疏性或学习字典约束重建结果，也可结合非局部相似性、块匹配、低秩分解和统计先验等信息进一步改善恢复质量。总体而言，压缩感知及稀疏表示方法适合构建可解释的图像增强模型，但其增强效果往往依赖先验设计、字典表达能力和分块策略。若缺少对图像局部结构复杂度的自适应建模，固定尺度处理方式仍难以在噪声抑制、边缘保持和细节恢复之间取得稳定平衡。

1.2.2 深度学习在图像增强中的应用

深度学习方法近年来在医学图像合成和医学图像增强任务中得到了广泛应用。医学图像合成通常指从一种模态或一种退化观测生成另一种目标图像，例如由MRI生成合成CT、由低剂量图像恢复常规剂量图像，或由低分辨率图像恢复高分辨率图像。Nie等提出基于上下文感知生成对抗网络（Generative Adversarial Network，GAN）的医学图像合成方法，用于从MRI预测CT图像[8]；Han等使用深度卷积神经网络完成基于磁共振的合成CT生成，表明卷积神经网络（Convolutional Neural Network，CNN）能够学习医学图像模态之间的复杂非线性映射[9]。CNN在局部邻域特征提取方面具有优势，能够有效建模边缘、纹理和灰度过渡，但其感受野通常受卷积核大小和网络深度限制。

为增强长距离依赖建模能力，Transformer结构被引入医学图像分析任务。例如，TransUNet将Transformer作为医学图像编码器，用于提升医学图像分割中的全局上下文建模能力[10]。不过，自注意力机制的计算量通常随序列长度增长较快，在高分辨率图像增强中会带来较大的显存和计算压力。状态空间模型（State Space Model，SSM）是近年来视觉任务中的重要建模方向。Mamba通过选择性状态空间机制使模型参数随输入特征动态变化，并实现了随序列长度近似线性增长的计算复杂度[11]。在视觉任务中，Vision Mamba将图像块作为序列输入并引入双向状态空间建模，VMamba进一步通过二维选择性扫描机制将Mamba结构扩展到视觉骨干网络[12,13]。在医学影像领域，U-Mamba将CNN局部建模能力与SSM长距离依赖建模能力结合，用于生物医学图像分割任务[14]。与传统CNN相比，SSM更适合捕获远距离结构关联；与Transformer相比，SSM在长序列建模中具有更低的计算

复杂度；与普通循环网络相比，现代选择性 SSM 可以根据输入动态调节状态更新过程。因此，SSM 为医学图像增强中的高分辨率特征保持和长距离结构建模提供了可行的模型选择。

总体而言，深度学习图像增强方法能够通过端到端训练学习复杂退化过程与目标图像之间的映射关系，在去噪、超分辨率、模态合成和图像恢复等任务中具有较强的非线性表达能力。CNN 类方法侧重局部纹理和边缘恢复，Transformer 类方法侧重全局依赖建模，SSM 类方法则在长序列建模效率方面具有优势。然而，医学图像增强不仅要求视觉质量提升，还要求组织结构、病灶形态和定量测量关系保持可靠。因此，如何结合局部细节建模、长距离依赖建模和医学结构约束，仍是深度学习医学图像增强方法需要重点解决的问题。

1.2.3 超声图像增强研究现状

超声图像增强是医学图像增强中的重要分支，其主要任务包括散斑噪声抑制、组织边界保持、局部对比度提升和空间分辨率增强。与自然图像以及 CT、MRI 等医学影像不同，超声图像由声束发射、组织散射、回波接收和波束合成共同决定，图像纹理中既包含随机散斑成分，也包含与组织微观结构相关的有效信息。因此，超声图像增强不能简单等同于普通图像去噪或超分辨率，而需要在降低散斑干扰的同时尽量保持真实组织边界、弱小目标和散斑统计特征。若增强强度不足，背景噪声和模糊问题仍然存在；若增强强度过高，则可能造成边缘过平滑、亮点目标展宽、真实纹理丢失或伪纹理生成。

针对超声图像去噪，传统方法主要包括中值滤波、各向异性扩散、非局部均值、小波阈值、变分模型、块匹配和稀疏表示等。这些方法通常具有较强可解释性，能够在一定程度上降低散斑噪声并改善局部对比度。其中，稀疏表示和字典学习方法与压缩感知理论关系密切，能够利用稀疏性恢复感兴趣区域（Region of Interest，ROI）的局部结构。已有研究尝试将稀疏表示、字典学习和块匹配思想引入超声散斑抑制任务。例如，Michailovich 等研究了医学超声图像散斑噪声的建模和预处理问题，指出简单假设对数域噪声为白高斯噪声存在局限[15]；Deka 等将学习字典用于医学超声图像去散斑，利用稀疏表示降低乘性散斑噪声影响[16]；后续一些方法进一步结合块匹配、奇异值分解（Singular Value Decomposition，SVD）或统计纹理信息，提高了超声图像中局部结构的恢复能力[17]。但是，现有方法大多仍以固定块大小、固定变换或固定统计模型为基础，未充分利用超声图像中背景区域适合大

尺度平滑、感兴趣区域需要小尺度保持的结构差异。因此，如何提取并利用超声图像局部结构复杂度信息，是压缩感知超声去噪进一步改进的关键问题。

超声超分辨率任务可以看作医学图像合成思想在同一模态内部的迁移：输入与输出均为超声图像，但二者对应不同空间分辨率、不同波束线数或不同采样条件。自然图像超分辨率研究为该任务提供了端到端学习框架，医学图像合成研究则表明深度网络能够学习具有医学结构约束的图像到图像映射关系。以 SwinIR 为代表的 Transformer 图像恢复模型表明，窗口自注意力机制可用于图像恢复任务中的结构与纹理重建[18]。然而，超声图像纹理由声学散射、波束合成和散斑统计共同决定，直接将通用超分辨率模型迁移到超声图像中，可能产生伪纹理或削弱真实散斑分布。已有深度学习超声超分辨率研究表明，CNN 能够提高 B 模式（Brightness Mode，B-mode）超声图像或超声定位显微成像的空间分辨率[19,20]，但 CNN 主要依赖局部卷积操作，对远距离组织轮廓、全局上下文关系和频谱结构的建模能力仍然有限。Transformer 虽然能够增强长距离依赖建模，但在高分辨率超声图像上计算开销较大；SSM 则兼具长距离序列建模能力和较低计算复杂度，为超声图像超分辨率提供了新的可行路径。

综上，传统滤波、统计建模和稀疏表示方法具有较好可解释性，但对复杂结构和多尺度区域的自适应能力有限；深度学习与长距离序列建模方法表达能力较强，但仍需控制伪纹理生成和医学结构失真风险。因此，超声图像增强仍需在噪声抑制、结构保持和空间分辨率提升之间取得平衡，并兼顾方法的可解释性与计算效率。

1.3 本文的主要研究内容

围绕超声图像增强中噪声抑制、结构保持与分辨率提升难以兼顾的问题，论文形成结构先验提取—自适应压缩感知去噪—状态空间超分辨率增强的串联技术路线。第一阶段从高效视频编码（High Efficiency Video Coding，HEVC）块划分中提取局部结构复杂度；第二阶段提出结构先验引导的自适应分块 K-SVD 去噪方法，并将其记为 Block K-SVD，将该先验转化为区域自适应去噪尺度；第三阶段构建面向医学超声 B 模式图像超分辨率的 USR-Mamba 网络，对去噪后的低波束线数图像进行超分辨率重建。三个阶段依次解决结构表征、尺度选择和空间响应恢复问题。

总体技术路线如图 1-3 所示。原始低波束线数超声图像经结构先验提取和自适应压缩感知去噪后，形成噪声水平较低且局部结构相对稳定的前级结果，再作为超分辨率网络输入；最终输出与原生高波束线数图像进行定量和主观评价。

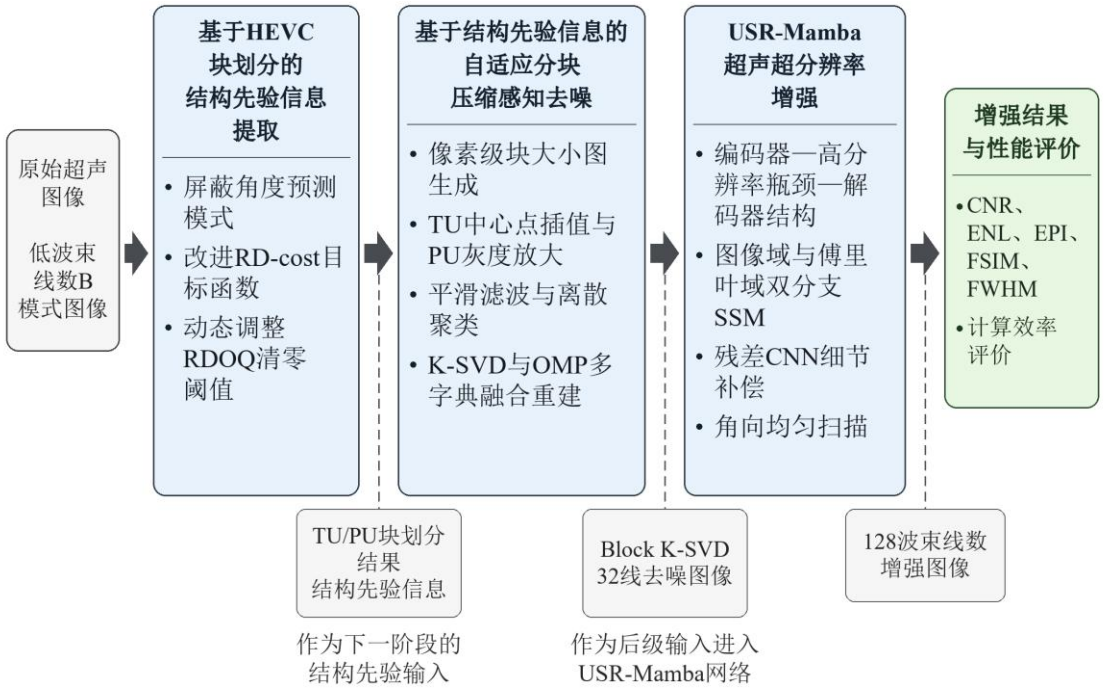


图 1-3　本文总体技术路线

如图 1-3 所示，研究对象为 32 波束线数超声 B 模式图像。首先，改进 HEVC 帧内编码流程，使预测单元（Prediction Unit，PU）和变换单元（Transform Unit，TU）的划分结果能够反映边缘、亮点、纹理与平滑背景的结构差异；随后，将离散块划分解析为像素级块大小图，由 Block K-SVD 在不同区域选择相应重建尺度；最后，将去噪结果输入 USR-Mamba，学习 32 线图像到原生 128 线参考图像之间的映射关系。

第一项工作研究基于 HEVC 块划分的结构先验提取。原始编码器以压缩效率和视觉失真为主要目标，平直边缘与高频纹理区域可能划分过粗。为此，限制帧内预测模式以降低平直边缘的预测充分程度，在率失真成本（Rate-Distortion Cost，RD-cost）中引入结构失真权重，并依据梯度能量调整量化清零阈值，使复杂结构倾向于细分、平滑背景保留较大块。该阶段输出并非用于评价压缩码流，而是形成后续算法可读取的块尺度先验；实验同时覆盖五类典型结构及 32 线、128 线成像条件，通过可视化和感兴趣区域内外变换单元平均大小检验其结构区分能力与稳定性。

第二项工作研究结构先验引导的自适应分块压缩感知去噪。针对固定分块只能在背景抑噪与细节保持之间选择单一尺度的问题，将离散变换单元划分转换为像素级块大小图，并结合中心点插值、预测单元灰度调节、平滑滤波和离散聚类生

成有限种重建尺度。不同尺度区域分别进行字典学习和稀疏重建，再以加权方式融合，使平滑背景采用较大块抑制散斑，边缘、纹理和亮点区域采用较小块保持结构。实验与多种固定块大小方法进行对照，从噪声抑制、结构保持、亮点空间响应和计算时间四个方面评价自适应尺度的综合效果。

第三项工作研究医学超声 B 模式图像超分辨率网络 USR-Mamba。网络采用编码器—高分辨率瓶颈—解码器结构，在瓶颈中设置图像域与傅里叶域状态空间分支，以建模组织轮廓、频谱分布和长距离上下文；残差卷积用于补偿局部边缘与亮点细节，角向均匀扫描用于减弱栅格扫描的方向偏置。实验以 Block K-SVD 32 线去噪图像为输入，从目标—背景对比、感知相似性和亮点空间响应等方面与原生 128 线图像比较，并设置纯卷积瓶颈、无频域分支、无卷积精炼和栅格扫描等消融组，以分析各结构模块的贡献。

全文共 4 章。第 1 章介绍研究背景与意义，梳理压缩感知、深度学习和超声图像增强相关工作，并给出总体技术路线；第 2 章分析 HEVC 帧内编码的块划分机制，提出面向超声结构先验提取的预测、率失真成本和量化策略改进，并验证其对五类典型结构及两种波束线条件的区分能力；第 3 章将块划分转换为像素级自适应尺度，研究多字典 K-SVD 与 OMP 融合去噪，并与固定分块方法比较噪声抑制、结构保持、空间响应和计算效率；第 4 章研究 USR-Mamba 超分辨率网络、数据处理和结构消融，评价其与原生 128 线参考图像的接近程度；结论归纳主要结果、验证范围和后续研究方向。

第 2 章　基于 HEVC 块划分的超声图像结构先验信息提取方法

2.1　引言

自适应压缩感知去噪需要在平滑背景中增强抑噪，同时在组织边界、纹理和弱小目标处保持细节。统一分块尺度难以兼顾两类需求，因此需在去噪前获得能够反映局部结构复杂度的先验信息。HEVC 帧内编码会依据灰度变化、预测残差和编码代价生成多层级块划分，可为该先验提供可解释的块尺度描述。

本章先介绍 HEVC 帧内编码中的分块、预测、变换量化与编码决策，再面向超声细微结构改进预测模式、率失真成本和量化清零策略；最后通过块划分可视化及感兴趣区域内外变换单元平均大小，评价结构区分能力，并为第 3 章自适应去噪提供输入。

由于 HEVC 的原始目标是压缩效率与视觉失真控制，平直边缘和高频纹理可能因预测充分或比特约束而保留较大块。为使块划分更适合作为结构先验，需分析并调整预测、量化和编码决策之间的耦合关系。

2.2　面向自然图像保真压缩的 HEVC 块划分方法

HEVC 由 ITU-T VCEG 与 ISO/IEC MPEG 共同制定，其标准文本对应 ITU-T H.265 也即 ISO/IEC 23008-2，并于 2013 年完成第一版标准化[21]。与此前广泛采用的 H.264 也即 MPEG-4 AVC 相比，HEVC 的设计目标是在相同主观质量下实现约 50%的码率节省[22]。在帧内编码方面，HEVC 采用四叉树递归块划分、空间邻域样本预测、变换量化和率失真优化决策等工具，以提高图像内空间冗余去除能力[22,23]。由于视频序列由连续帧图像构成，而帧内编码仅依赖当前图像内部已重建邻域样本，因此 HEVC 帧内压缩流程同样可用于静态图像编码与块划分分析；基于 HEVC 的高效率图像文件格式（High Efficiency Image File Format，HEIF）也证明了 HEVC 帧内编码在静态图像存储中的适用性[24]。

HEVC 帧内编码主要包括块划分、帧内预测、变换量化和编码决策四个环节。编码器先依据局部结构递归划分，再对预测残差执行变换、量化和熵编码。由于块划分决策受各环节共同影响，本章将其作为超声结构先验的提取依据，其中帧内预

测对划分结果的影响尤为显著。这种协同关系使块划分结果同时反映局部结构特征与编码代价。

传统非预测图像压缩算法通常对每个图像块进行相对独立的编码，未充分利用相邻图像块之间的空间相关性。基于预测的图像压缩算法利用已编码并重建的邻近图像块预测当前图像块，生成预测块；随后由原始图像块减去预测块得到残差块，并对残差块进行变换和量化，以降低残差信号能量并提高压缩效率。基于预测的图像压缩流程如图 2-1 所示。

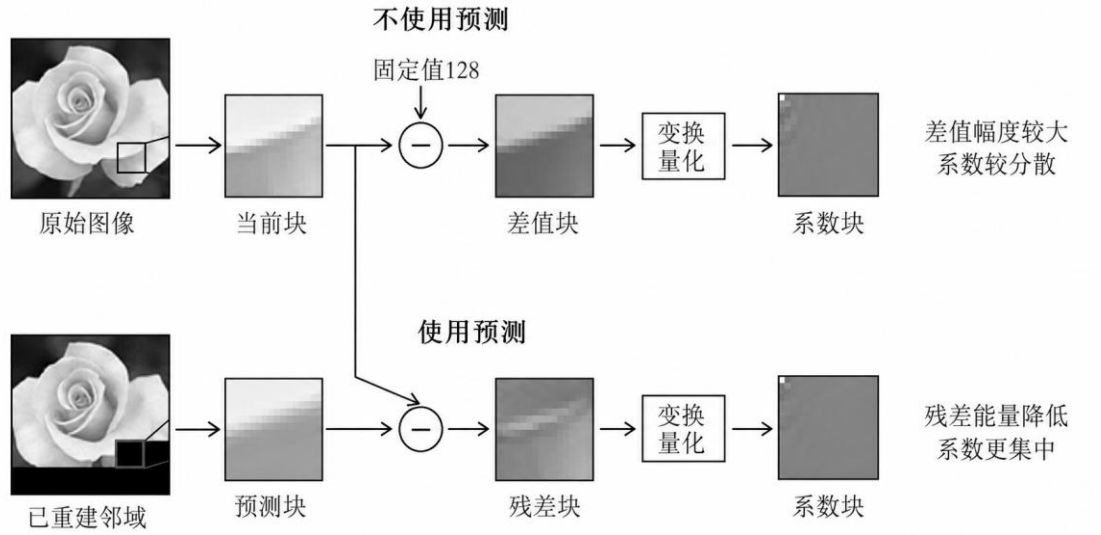


图 2-1　基于预测的图像压缩流程

联合图像专家组（Joint Photographic Experts Group，JPEG）标准之后的多种主流图像编码标准均采用预测—残差编码框架，其中包括基于 HEVC 的 HEIF 标准。与 H.264/MPEG-4 AVC 等早期标准相比，HEVC 在块划分决策和预测模式设计上更为灵活。以 H.264 和 HEVC 为例，前者支持 4×4 至 16×16 大小的预测块，且每个块至多支持 9 种预测模式；后者支持 4×4 至 32×32 大小的预测块，且每个块至多支持 35 种预测模式。

HEVC 编码器以块为基本单位执行预测与变换，帧内编码中使用的块为大小可变的正方形。对于灰度变化剧烈、纹理复杂的区域，采用较小块有助于使用更具针对性的预测模式，从而获得更精细的预测结果；对于灰度变化平缓的区域，采用较大块则可减少候选模式数量，降低编码复杂度并提高压缩效率。这种块尺度选择兼顾局部预测精度与整体编码开销。不同区域的块尺度差异也为后续结构分析提供了直观依据。

2.2.1 多层级分块

为兼顾复杂区域与平滑区域的编码需求，HEVC 将图像依次组织为 CTU、CU、PU 和 TU 四个层级，如图 2-2 所示。该多层级结构支持可变块大小，也是后续利用块划分表征局部结构复杂度的基础。

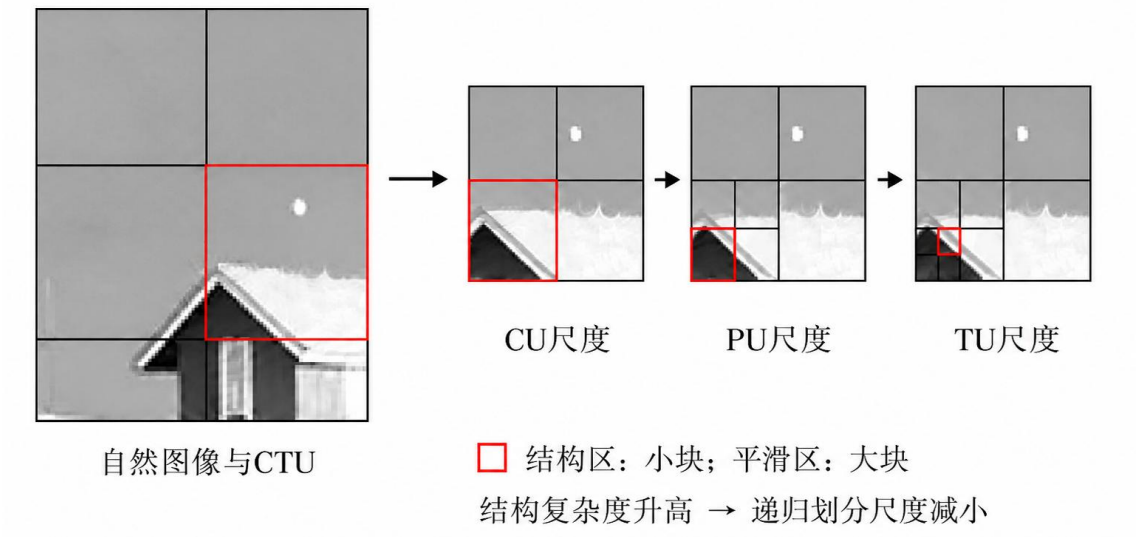


图 2-2 HEVC 多层级分块结构

HEVC 编码器首先将图像划分为多个编码树单元（Coding Tree Unit，CTU），大小可以是 64×64、32×32 或 16×16。对于每张图像，CTU 的大小是固定的，本文所采用的编码器实现使用 32×32 固定大小的 CTU。随后，编码器从上到下、从左到右地遍历每个 CTU 并进行编码。CTU 相当于 HEVC 编码过程中的最大处理单元，也是后续递归划分和模式决策的起始单元，其内部是否继续细分，主要由当前区域的灰度变化、预测残差和编码代价共同决定。对于结构较复杂或灰度变化较剧烈的区域，编码器通常倾向于继续划分以提高局部预测精度；对于灰度分布较平缓的区域，则更可能保留较大的处理单元以降低编码开销。

每个 CTU 按照四叉树递归的方式划分为一个或多个编码单元（Coding Unit，CU），大小可以是 64×64、32×32、16×16 和 8×8，但不能超过 CTU。64×64、32×32 和 16×16 大小的 CU 可以继续划分为更小的 CU，而 8×8 大小的 CU 不再继续划分为 CU。对于纹理复杂、边缘明显或局部结构变化剧烈的区域，编码器通常更倾向于使用较小 CU；对于灰度分布平缓、结构变化较弱的背景区域，则更可能保留较大 CU。因此，CU 层级的递归划分能够初步反映图像局部区域的结构复杂程度。

其分块尺度可作为后续区分复杂结构与平滑背景的初步依据。不同尺度之间的递归关系还能反映结构变化的层级特征。

每个 CU 可以被划分为一个或多个 PU，每个 PU 独立持有一个预测模式。对于 8×8 大小的 CU，可以在不划分即自身作为一个 PU 和划分为四个 4×4 大小的 PU 两种模式中进行选择；而对于 64×64、32×32 和 16×16 大小的 CU，只能自身作为一个 PU。与 CU 不同，PU 的划分不是递归的，每个停止递归划分的 CU 要么自身作为一个 PU，要么被划分为四个 PU，而这些 PU 不再继续划分。PU 主要服务于帧内预测过程，其划分结果与预测模式选择共同决定当前区域的预测精度和残差信号分布。

每个CU按照四叉树递归方式划分为一个或多个TU，后者大小可以为32×32、16×16、8×8 或 4×4。TU 是变换与量化的基本执行单位，其预测模式由所在 PU 决定，且 TU 不能跨越 PU 边界。对于不再递归划分的 64×64 大小 CU，编码器至少将其划分为四个32×32大小TU，也可继续递归划分为16×16、8×8 或 4×4 大小 TU；这些 TU 共享所在 CU，即所在 PU 指定的同一种预测模式。对于不再递归划分的 32×32 和 16×16 大小 CU，编码器可将其递归划分为一个或多个 TU，这些 TU 同样共享所在 PU 指定的预测模式。对于 8×8 大小 CU，若该 CU 未划分为四个 PU，则可选择不划分并以自身作为一个 TU，也可划分为四个 4×4 大小 TU；若该 CU 已划分为四个 4×4 大小 PU，则必须相应划分为四个 4×4 大小 TU，且每个 TU 采用其所在 PU 指定的预测模式。

2.2.2 帧内预测

HEVC 规定了 35 种帧内预测模式，不同模式会依据已重建邻域像素生成不同形式的预测块，如图 2-3 所示。其中，PLANAR 模式通过水平和垂直方向的线性插值描述灰度缓慢变化，适合预测图像呈线性过渡的区域；DC 模式利用邻域参考像素的平均值构造预测块，适合预测灰度分布较为平坦的区域；角度模式则沿不同方向延拓边界像素，适合预测图像中的方向性纹理和边缘结构。对于每个 TU，其预测块由所在 PU 指定的预测模式决定，即编码器根据原始图像块周围已重建边界像素执行相应预测算法，得到用于后续残差计算和变换量化的预测结果。对于超声图像，组织边界、条带状纹理和局部亮点通常表现出不同的方向性，而背景区域的灰度变化相对平缓。角度模式可沿特定方向延拓边界信息，PLANAR 和 DC 模式则适合描述缓慢变化区域。各候选模式产生的残差分布不同，并会进一步改变变换

系数和编码代价。编码器对这些结果进行比较后确定当前 PU 的预测方式，因此帧内预测模式的选择也会参与块划分决策，并影响块尺度对局部结构复杂度的表征。

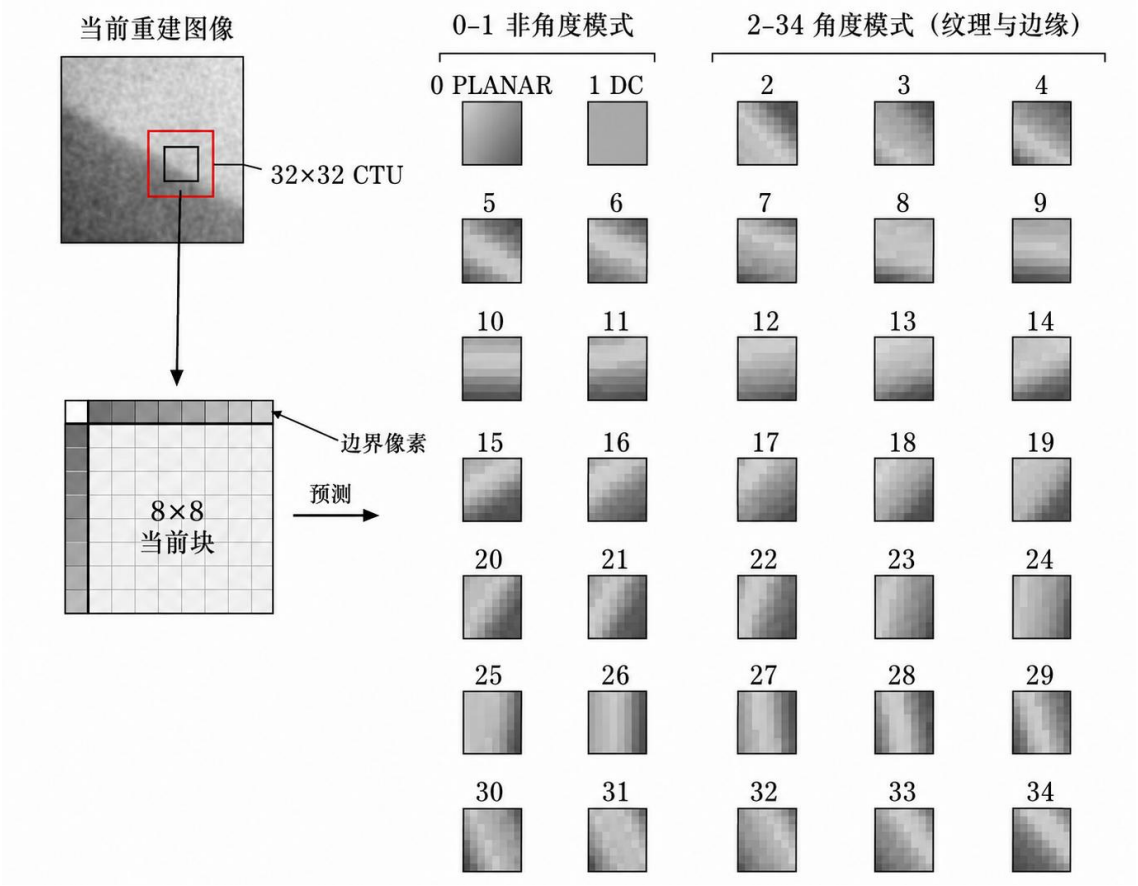


图 2-3　HEVC 帧内预测模式

2.2.3　变换与量化

在对每个 TU 执行预测算法后，将 TU 对应的原始图像块减去预测块，即可得到残差块。变换负责将残差块转换至频域，得到系数块；经过量化与反量化，再由反变换转换回空间域，得到重建的残差块；加至预测块，即可得到重建的图像块。每个 TU 的重建图像块将提供下一个 TU 预测所需的边界像素。

大部分 HEVC 编码器实现采用率失真优化量化（Rate-Distortion Optimized Quantization，RDOQ）方法对系数块进行量化，该步骤是 HEVC 实现高效率编码的重要环节。RDOQ 将量化过程与率失真优化（Rate-Distortion Optimization，RDO）准则相结合，用于在失真和编码比特数之间进行权衡。候选量化值的比较结果将直接决定当前系数的保留或清零。

对于一个变换系数c_i，给定多个可选的量化值$l_{i,1},l_{i,2},\ldots,l_{i,k}$，并用 RDO 准则挑选出最优的量化值：

$$l_i^* = \underset{k}{\operatorname{argmin}}\left\{D\left(c_i,l_{i,k}\right)+\lambda\cdot R\left(l_{i,k}\right)\right\} \tag{2-1}$$

其中，l_i^*为最优量化值，$D\left(c_i,l_{i,k}\right)$表示将变换系数$c_i$量化为$l_{i,k}$所产生的失真，$R\left(l_{i,k}\right)$表示该量化值对应的编码比特数；$\lambda$为拉格朗日乘子，用于控制量化失真与编码比特数之间的权衡。

2.2.4 编码决策

前文介绍的块划分、帧内预测和变换与量化是 HEVC 编码器的基础构件，而编码决策环节负责递归调用这些模块，在多个候选编码方案中搜索最优或次优方案，这构成了 HEVC 实现高效压缩的核心机制。这些候选编码方案主要区别在于块划分方式和预测模式不同：对于每个 CTU，编码器递归尝试不同的 CU、PU 和 TU 划分方式，并选择率失真成本较低的方案；对于每个 PU，编码器依次尝试 35 种预测模式，并选择与局部图像结构匹配度较高的模式。

为评价不同候选编码方案，HEVC 编码决策通常建立在拉格朗日率失真优化框架上，通过同时衡量重建失真与编码比特数，在多个候选块划分、预测模式和量化结果之间选择代价较低的方案[25,26]。在具体实现中，HEVC 引入 RD-cost 函数作为 RDOQ 与编码模式选择的重要判据。对于每一种候选方案，其包含的每个 TU 均需按照式(2-2)计算 RD-cost，并据此参与最优方案选择：

$$\mathrm{RD}_{\mathrm{cost}} = D_{\mathrm{SSE}}\left(X_{\mathrm{orig}},X_{\mathrm{rcon}}\right)+\lambda\cdot R \tag{2-2}$$

其中，X_{rcon}表示重建图像块，X_{orig}表示原始图像块，D_{SSE}为平方误差和函数，R为量化当前 TU 所需的比特数，λ是与量化参数正相关的标量常系数。显然：$D_{\mathrm{SSE}}\left(X_{\mathrm{orig}},X_{\mathrm{rcon}}\right)$用来评估量化当前 TU 的失真成本，$\lambda\cdot R$用来评估量化当前 TU 的比特数成本；两者相加所得到的$\mathrm{RD}_{\mathrm{cost}}$即为综合考虑量化失真和量化所需比特数的目标函数，越大则说明当前编码方案越差。

对于每张图像，HEVC 编码器从上到下、从左到右地遍历每个 CTU，递归尝试不同的编码方案，并分别计算和评价每种编码方案中每个 TU、每种预测模式对应的 RD-cost 目标函数。编码器根据各候选方案的率失真成本进行比较和选择，最终得到如图 2-4 所示的块划分决策。

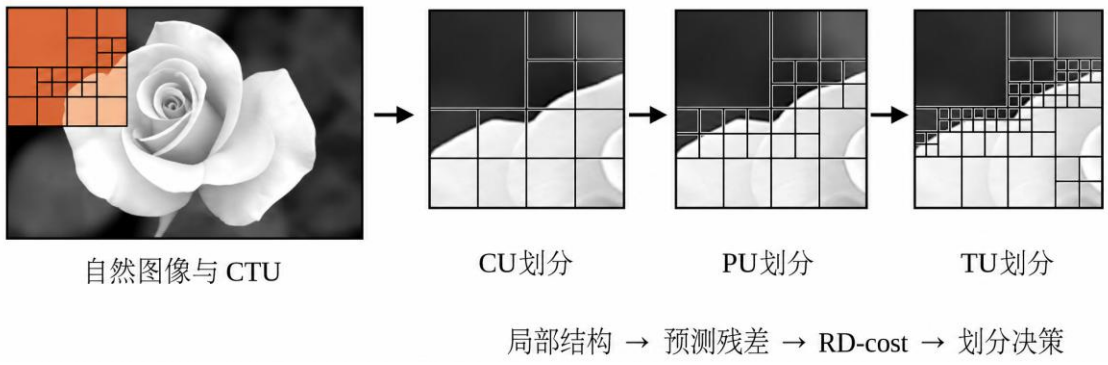


图 2-4　HEVC 块划分决策流程

由于递归搜索全局最优编码方案的计算开销较大，部分 HEVC 编码器实现会对搜索树进行剪枝，即从 35 种预测模式中筛选若干候选模式参与计算。本文所采用的编码器实现已完成面向结构先验提取任务的修改与重新编译，后续分析中不再考虑搜索树剪枝对块划分结果的影响。

2.3　面向超声结构先验提取的 HEVC 块划分方法

现有 HEVC 编码器主要面向视觉失真控制和压缩效率，而本章将块划分决策作为结构先验，并用于指导后续压缩感知去噪。因此，评价重点不是重建图像质量或码率，而是块划分对超声图像局部结构复杂度的表征能力。

为此，在保留 HEVC 多层级分块机制的基础上，对帧内预测、率失真成本和量化策略进行针对性改进，使组织边界、亮点目标和高频纹理区域倾向于细分，弱回声背景和平滑区域保留较大块。本章以轻量级 ImCvt 编码器为实现基础，便于修改相关模块。

2.3.1　结构先验提取目标导向 HEVC 流程优化

超声图像中高回声区域与低回声区域之间可能形成明显边缘；如图 2-5 所示，当边缘近似平直且方向性较强时，角度模式往往能够较准确地完成预测，此时 CTU 可能不再继续划分，而直接形成 32×32 大小的 CU、PU 和 TU。其原因在于角度模式已经能够较好拟合该类局部结构，使预测残差能量较低，残差系数量化所需成本也相对较小。从编码角度看，较大的处理单元可以减少划分标志和模式信息所占比特数，因此即使边缘位置具有较强梯度，较小的残差成本仍可能使编码器保留大块。此时块尺度主要反映预测是否充分，而不能完整表示边缘附近的细节变化。这一偏差会限制其作为结构先验的区分能力。

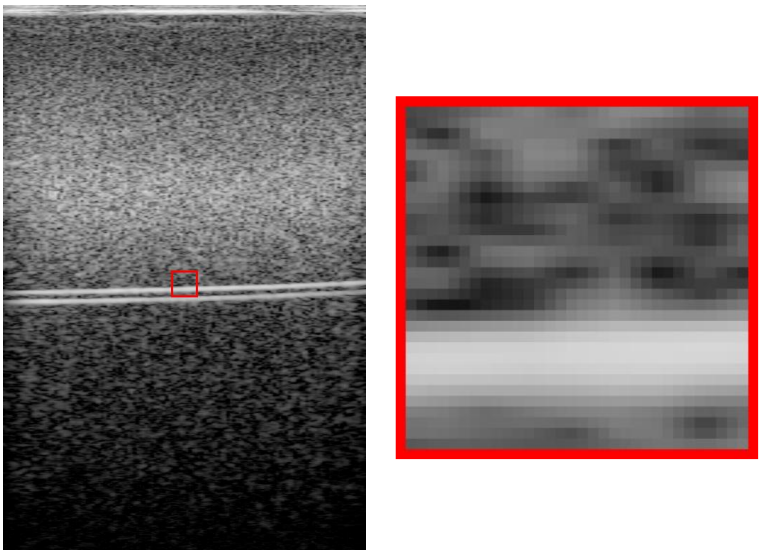


图 2-5　超声图像中的平直边缘示例

对于感兴趣区域内的平直边缘，32×32 块难以提供足够精细的结构先验。为提高此类区域的划分精度，修改 ImCvt 帧内预测模块，屏蔽角度模式，仅保留 PLANAR 和 DC 模式，以降低平直边缘的预测充分程度并促进继续细分。

2.3.2　基于动态权重的率失真成本目标函数设计

在率失真成本中引入基于原始图像块结构复杂度的自适应机制，利用结构失真和梯度能量动态调整失真项与比特数项权重。

改进前的 RD-cost 目标函数 $\mathrm{RD}_{\mathrm{cost}}$ 仅使用平方误差和函数 D_{SSE} 作为失真项，且失真项和比特数项各自的权重完全由量化参数 qpd6 决定：

$$\mathrm{RD}_{\mathrm{cost}} = w_{\mathrm{d}}\left(\mathrm{qpd6}\right)\cdot D_{\mathrm{SSE}} + w_{\mathrm{b}}\left(\mathrm{qpd6}\right)\cdot R \tag{2-3}$$

其中：

$$D_{\mathrm{SSE}} = \sum_{i=0}^{\mathrm{sz}-1}\sum_{j=0}^{\mathrm{sz}-1}\left(X_{i,j}^{\mathrm{orig}} - X_{i,j}^{\mathrm{rcon}}\right)^2 \tag{2-4}$$

$$\begin{cases} w_{\mathrm{d}}\left(\mathrm{qpd6}\right) = \left[11,11,11,5,1\right]_{\mathrm{qpd6}} \\ w_{\mathrm{b}}\left(\mathrm{qpd6}\right) = \left[1,4,16,29,23\right]_{\mathrm{qpd6}} \end{cases} \tag{2-5}$$

改进后的 RD-cost 目标函数 $\mathrm{RD}'_{\mathrm{cost}}$ 在 D_{SSE} 的基础上追加梯度差惩罚，构造结构失真函数 D_{struct}；同时，根据当前 TU 的梯度能量函数动态调整失真项和比特数项权重。这种权重调整使结构保真与码率约束随局部内容自适应变化。梯度能量函数

定义为当前 TU 内各像素横向与纵向梯度绝对值之和的平均值，用于衡量当前 TU 的结构复杂度，记为G_{TU}，其计算方式见式(2-12)：

$$\mathrm{RD}'_{\mathrm{cost}} = w'_{\mathrm{d}} \cdot D_{\mathrm{struct}} + w'_{\mathrm{b}} \cdot R \tag{2-6}$$

其中：

$$D_{\mathrm{struct}} = D_{\mathrm{SSE}} + \sum_{i=1}^{\mathrm{sz}-2}\sum_{j=1}^{\mathrm{sz}-2}\left(\left|G_x^{\mathrm{orig}} - G_x^{\mathrm{rcon}}\right| + \left|G_y^{\mathrm{orig}} - G_y^{\mathrm{rcon}}\right|\right) \tag{2-7}$$

$$\begin{cases} G_x^{\mathrm{orig}} = X_{i,j+1}^{\mathrm{orig}} - X_{i,j-1}^{\mathrm{orig}} \\ G_y^{\mathrm{orig}} = X_{i+1,j}^{\mathrm{orig}} - X_{i-1,j}^{\mathrm{orig}} \end{cases} \tag{2-8}$$

$$\begin{cases} G_x^{\mathrm{rcon}} = X_{i,j+1}^{\mathrm{rcon}} - X_{i,j-1}^{\mathrm{rcon}} \\ G_y^{\mathrm{rcon}} = X_{i+1,j}^{\mathrm{rcon}} - X_{i-1,j}^{\mathrm{rcon}} \end{cases} \tag{2-9}$$

自适应权重满足：

$$w'_{\mathrm{d}} = \begin{cases} \min\left\{w_{\mathrm{d}}\left(\mathrm{qpd6}\right) + \min\left\{G_{\mathrm{TU}} - 1, 12\right\}, 24\right\}, G_{\mathrm{TU}} > 2 \\ w_{\mathrm{d}}\left(\mathrm{qpd6}\right), G_{\mathrm{TU}} \le 2 \end{cases} \tag{2-10}$$

$$w'_{\mathrm{b}} = \begin{cases} \max\left\{w_{\mathrm{b}}\left(\mathrm{qpd6}\right) - \min\left\{G_{\mathrm{TU}} - 1, 12\right\}, 1\right\}, G_{\mathrm{TU}} > 2 \\ w_{\mathrm{b}}\left(\mathrm{qpd6}\right), G_{\mathrm{TU}} \le 2 \end{cases} \tag{2-11}$$

其中：

$$G_{\mathrm{TU}} = \frac{1}{\mathrm{sz}^2}\sum_{i=1}^{\mathrm{sz}-2}\sum_{j=1}^{\mathrm{sz}-2}\left(\left|G_x^{\mathrm{orig}}\right| + \left|G_y^{\mathrm{orig}}\right|\right) \tag{2-12}$$

该设计使 RD-cost 目标函数在复杂结构区域即$G_{\mathrm{TU}} > 2$区域自适应增大失真项权重，并同步减小比特数项权重，使编码决策不再单纯偏向码率更低的粗粒度划分结果。对于边缘、亮点和高频纹理等局部结构变化明显的区域，改进后的目标函数能够提高结构失真在总代价中的占比，从而引导编码器优先选择更细粒度的块划分方案，减少压缩效率约束对结构表征精度的干扰。

2.3.3 基于动态清零阈值的率失真优化量化方法

率失真优化量化是在候选量化等级之间以率失真成本为准则选择量化结果的过程。本节在其系数群清零判定环节引入结构复杂度自适应机制，通过梯度能量动态调整清零阈值，使高梯度区域保留更多高频系数。该机制使量化决策能够同时参

考系数代价与局部结构响应。该调整仅作用于系数群清零判定，不改变后续量化等级的比较流程。

改进前，每个 TU 的系数群（Coefficient Group，CG）清零阈值固定为：

$$T_{\mathrm{CG}}=\frac{9\times 2^{\mathrm{sft}}}{4}=9\times 2^{\mathrm{sft}-2} \tag{2-13}$$

其中，$\mathrm{sft}=\mathrm{LEVEL_SHIFT_TABLE}\left[\mathrm{sz}/8\right]+\mathrm{qpd6}$，sz 为当前 TU 大小，qpd6 为量化参数。

改进后，首先计算基础阈值：

$$T_{\mathrm{base}}=T_{\mathrm{CG}}=9\times 2^{\mathrm{sft}-2} \tag{2-14}$$

然后根据当前 TU 的梯度能量函数 G_{TU} 动态调整：

$$T_{\mathrm{adaptive}}=\begin{cases}\max\left\{\dfrac{T_{\mathrm{base}}}{2},1\right\}, G_{\mathrm{TU}}>2\\ T_{\mathrm{base}}, G_{\mathrm{TU}}\le 2\end{cases} \tag{2-15}$$

对于复杂结构区域即 $G_{\mathrm{TU}}>2$ 区域的系数块，自适应清零阈值 T_{adaptive} 相较 T_{CG} 至多降低一半，且最小值为 1。因此，该策略允许复杂结构区域保留更多变换系数，减少高频信息过早清零导致的过度平滑。该改进能够为 $\mathrm{RD}'_{\mathrm{cost}}$ 提供更稳定的量化结果，使编码器更准确地区分不同复杂程度的高频纹理区域，并为后续基于压缩感知的区域自适应去噪提供依据。

2.4 评价指标与结果分析

本章采用 YUView 对 HEVC 块划分决策进行可视化，并在同一超声图像上并列比较原始编码器、预测模式调整、率失真成本改进和量化清零策略改进后的结果。定性观察重点包括组织边缘是否继续细分、高频纹理是否形成更小变换单元、亮点目标轮廓是否得到响应，以及弱回声背景是否仍保留较大块。为减少仅凭视觉判断带来的主观性，进一步人工标定感兴趣区域与背景，遍历两类区域内的全部变换单元并分别统计平均大小。感兴趣区域平均块更小、背景平均块更大，且背景与感兴趣区域之比提高时，说明块划分能够更充分地区分局部结构复杂度。该评价关注的是块尺度作为结构先验的有效性，而非编码码率或重建图像质量，并为第 3 章按区域选择压缩感知重建尺度提供依据。

测试集由 40 张甲状腺与体模超声图像组成，按照亮带、亮斑、亮点、空洞和沟壑 5 类典型结构分组，每组 8 张，并同时覆盖 32 波束线数与 128 波束线数两种成像条件，如图 2-6 所示。亮带和沟壑用于考察连续边缘及方向性纹理，亮斑和亮点用于考察局部强回声结构，空洞用于考察低回声区域与周围组织之间的边界。32 线图像主要检验低分辨率、低采样条件下结构先验提取的稳定性，128 线图像用于分析细节增加后编码块划分对局部结构的响应。将五类结构与两种波束线条件结合，可避免结论仅依赖单一图像或单一结构类型，并为后续定性和定量比较提供一致的样本基础。

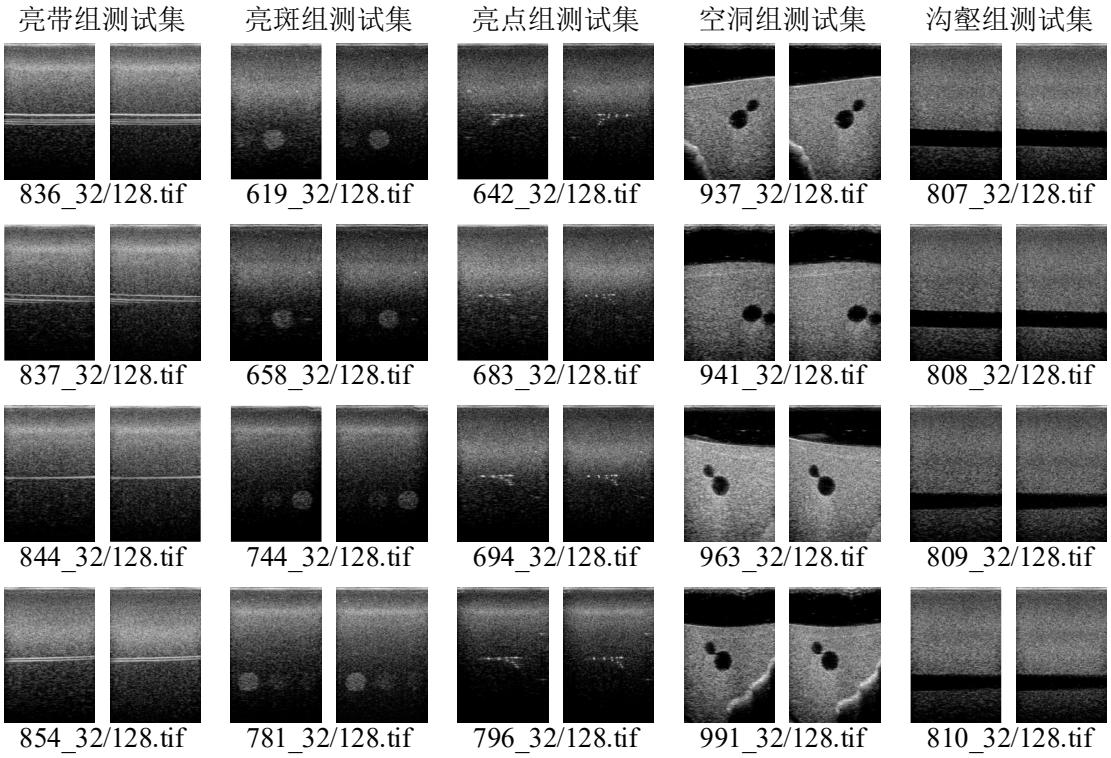


图 2-6　超声图像测试集选取

以空洞组图像 937_128.tif 为例，在保持输入图像、量化参数和其余编码条件一致的情况下，分别运行各改进版本的 ImCvt 编码器，并利用 YUView 叠加显示编码过程中生成的预测单元和变换单元划分，结果见图 2-7。子图按从上到下、从左到右的顺序依次为原始图像、未经改进的块划分、仅限制帧内预测模式后的块划分，以及联合改进率失真成本与量化清零策略后的块划分；右上子图中的不同颜色表示原始编码器选择的不同预测模式。通过同一图像的逐阶段对照，可分别观察空洞轮廓和组织边缘是否形成更细划分、高频纹理区域是否增加小变换单元，以及弱

回声背景是否仍以较大块为主，从而判断各项改进对结构响应的增量作用，并避免将图像内容差异误认为编码策略差异。统一的输入条件保证各阶段结果具有直接可比性。

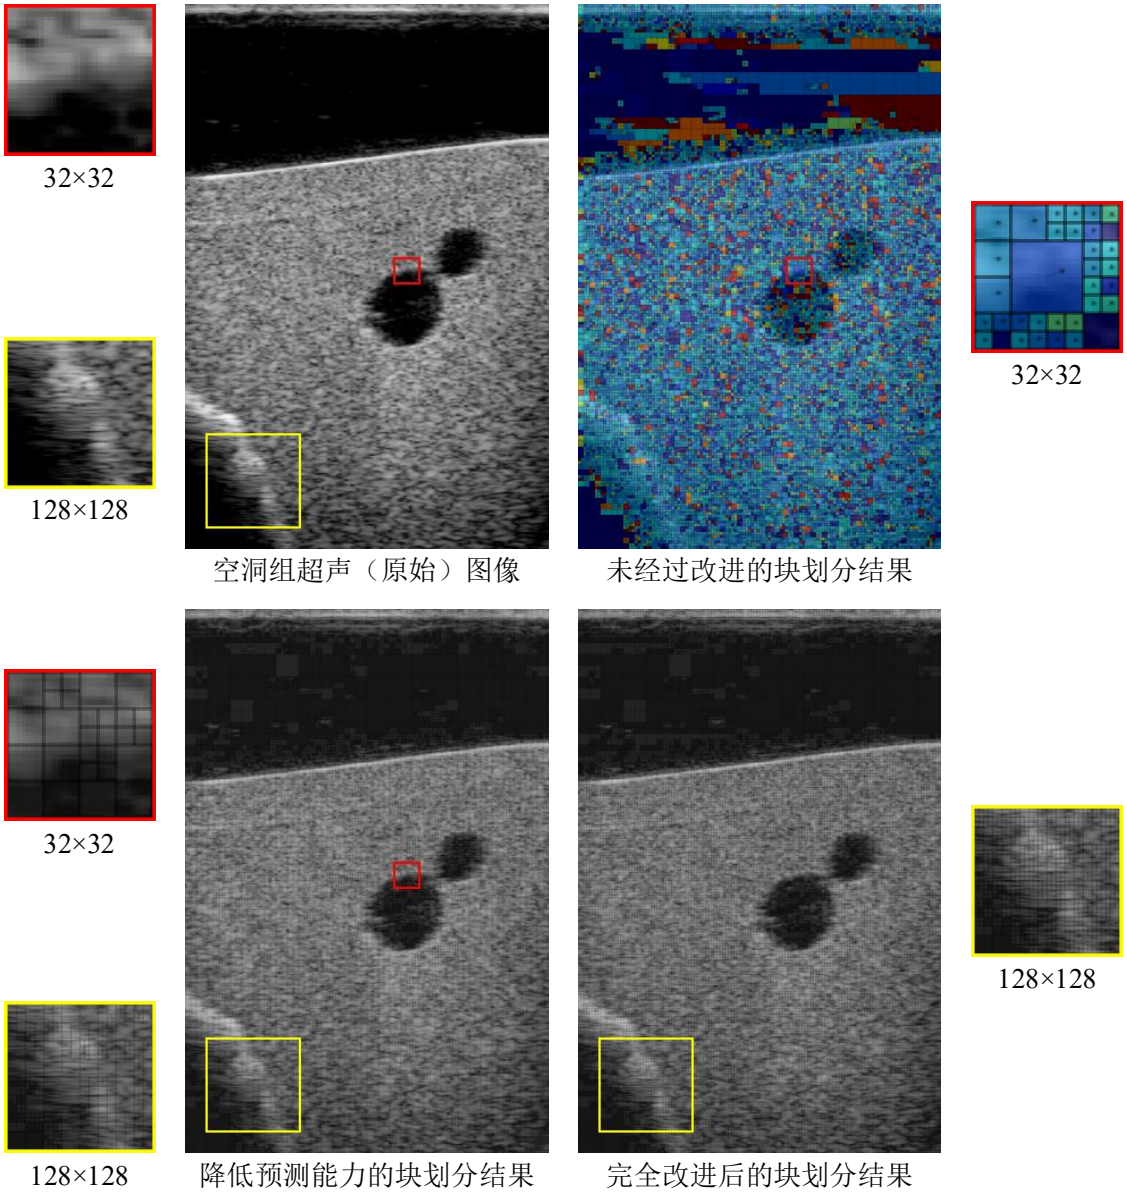
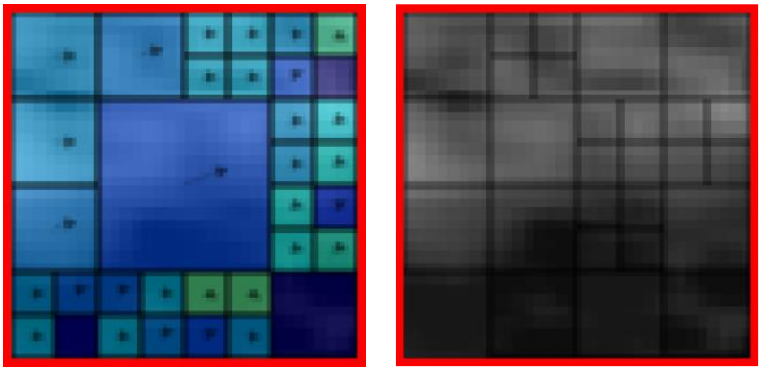


图 2-7　不同改进阶段的 YUView 块划分结果

在图 2-7 红色框所示区域，高回声与低回声区域之间存在较为平直的边缘。未经改进时，角度模式能够较准确地完成预测，导致对应残差的量化 RD-cost 较低，最终形成 16×16 大小的 TU。降低预测能力后，ImCvt 编码器仅保留 PLANAR 模式和 DC 模式，使该区域预测残差对应的量化 RD-cost 上升。为降低整体 RD-cost，

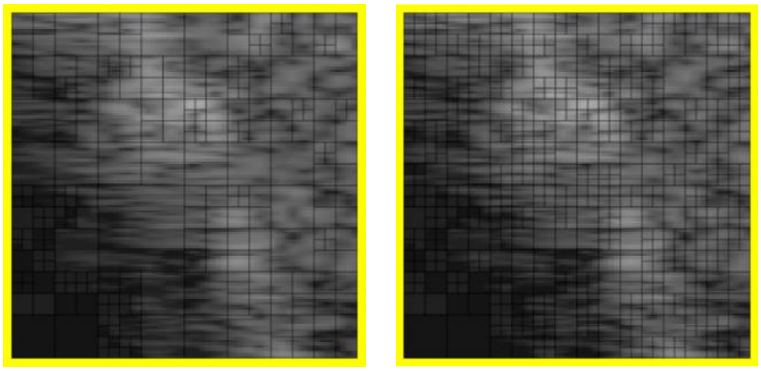
编码器进一步比较 4 个 8×8 大小 TU 方案与原 16×16 大小 TU 方案的代价，最终得到图 2-8 所示的更细粒度划分结果。这表明降低预测能力有助于提升边缘区域的块划分精度。该现象验证了预测模式约束对边界细分的直接作用。



降低预测能力前　　降低预测能力后

图 2-8　降低帧内预测能力前后的局部块划分对比

图 2-7 黄色框区域包含丰富高频纹理。仅降低预测能力虽可细化边缘划分，但对纹理响应仍不足；第 2.3.2 节和第 2.3.3 节进一步改进率失真成本与量化清零策略，增强高频系数保留。对比左下与右下子图可见，改进后纹理区域划分明显细化，如图 2-9 所示。

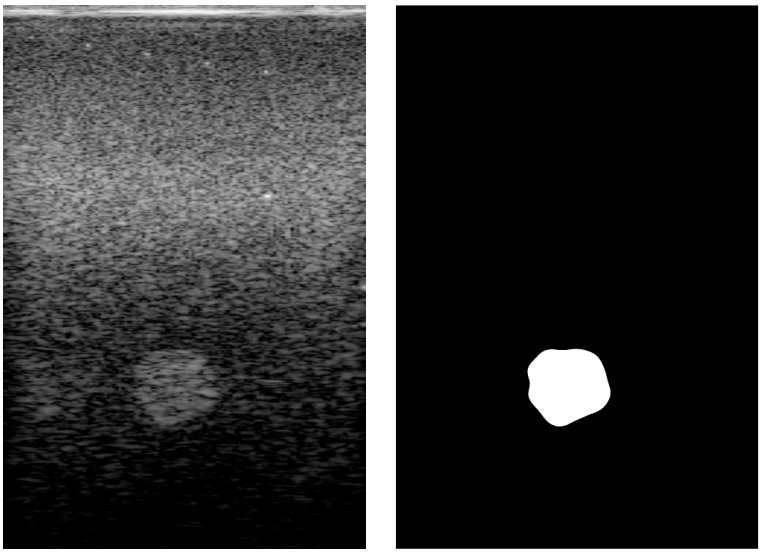


引入 RDOQ 改进前　　引入 RDOQ 改进后

图 2-9　引入 RDOQ 改进前后的局部块划分对比

为定量比较感兴趣区域与背景的划分差异，统计两类区域内全部变换单元的平均大小。以亮斑组图像 619_32.tif 为例，先通过二值化提取高灰度亮斑区域并生成遮罩，如图 2-10 所示，用于区分后续统计中的感兴趣区域与背景。二值化后对掩膜进行连通域筛选与孔洞填充，以减少散斑噪声形成的孤立像素，并统一不同编

码版本的区域判定标准。该处理还可保持掩膜边界的连贯性，避免局部噪点干扰区域归属。



亮斑组超声（原始）图像　　ROI（亮斑）遮罩图像

图 2-10　亮斑组 ROI 遮罩生成结果

按照相同方法生成亮斑组 8 张图像的感兴趣区域遮罩，并在各版本 ImCvt 编码器中增加块信息统计功能，记录编码树单元、编码单元、预测单元和变换单元的尺寸、坐标与数量。随后由 MATLAB 脚本依据遮罩分类变换单元，计算两类区域的平均块大小，结果见表 2-1 和表 2-2。各版本采用相同量化参数与掩膜坐标，以保证统计结果可比。

表 2-1　RDOQ 改进前亮斑组 ROI 内外 TU 平均大小统计

测试样本	感兴趣区域	背景区域	后者前者之差	后者前者之比
619_32.tif	6.382979	5.785256	-0.597723	0.906357
619_128.tif	6.103286	5.590444	-0.512842	0.915973
658_32.tif	6.426966	5.883663	-0.543303	0.915465
658_128.tif	6.165746	5.599746	-0.566000	0.908202
744_32.tif	6.612245	5.537928	-1.074317	0.837526
744_128.tif	6.105263	5.519465	-0.585798	0.904050
781_32.tif	7.136691	5.485234	-1.651457	0.768596
781_128.tif	5.723404	5.699316	-0.024088	0.995791
样本平均值	**6.332073**	**5.637631**	**-0.694441**	**0.893995**

表 2-2　RDOQ 改进后亮斑组 ROI 内外 TU 平均大小统计

测试样本	感兴趣区域	背景区域	后者前者之差	后者前者之比
619_32.tif	4.647059	4.618415	-0.028644	0.993836
619_128.tif	4.479616	4.671821	0.192204	1.042906
658_32.tif	4.718232	4.684073	-0.034159	0.992760
658_128.tif	4.574586	4.678125	0.103539	1.022634
744_32.tif	4.564972	4.672618	0.107646	1.023581
744_128.tif	4.618076	4.658768	0.040693	1.008812
781_32.tif	4.750000	4.568670	-0.181330	0.961825
781_128.tif	4.448179	4.564742	0.116563	1.026205
样本平均值	**4.600090**	**4.639654**	**0.039564**	**1.009070**

由表 2-1 和表 2-2 可见，引入改进 RDOQ 策略后，亮斑组超声图像 ROI 内外 TU 平均大小的统计关系发生变化。具体而言，ROI 内 TU 平均大小由 6.332073 降低至 4.600090，表明感兴趣区域的块划分尺度整体减小；背景区域与感兴趣区域 TU 平均大小之比由 0.893995 提高至 1.009070，说明块划分结果对两类区域的区分程度有所增强。同时，改进前背景区域与感兴趣区域 TU 平均大小之差的均值为负，改进后转为正值，表明编码器的划分策略由 ROI 相对更大块转变为 ROI 相对更小块、背景相对更大块。这一变化与后续去噪任务对结构保持和背景平滑的需求相一致。

2.5　本章小结

本章研究了利用 HEVC 块划分表征超声图像局部结构复杂度的方法。HEVC 帧内编码中的多层级分块、预测、变换量化和率失真决策能够形成结构相关的块尺度，但原始编码目标偏重压缩效率，不能直接满足超声结构先验提取需求。

为提高结构敏感性，编码器仅保留 PLANAR 和 DC 预测模式，并在率失真成本中加入梯度差惩罚、按梯度能量调整失真项与比特数项权重；同时动态降低高梯度区域的量化清零阈值，以保留更多高频系数。

亮斑组 ROI 内 TU 平均大小由 6.332073 降至 4.600090，背景与 ROI 之比由 0.893995 升至 1.009070，表明块划分可作为第 3 章的自适应尺度先验。

第 3 章　基于结构先验信息的自适应分块压缩感知去噪方法

3.1　引言

第 2 章得到的 HEVC 块划分能够区分结构复杂区域与平滑背景，但其输出仍是离散块级信息，不能直接作为 K-SVD 与 OMP 逐像素选择分块尺度的依据。本章的核心是将该先验转换为连续、稳定且可参与重建的像素级尺度约束。

本章先概述固定分块 K-SVD 与 OMP 去噪及其尺度折中，再通过变换单元中心插值、预测单元灰度调节、平滑聚类和多字典融合，将 HEVC 块划分转化为自适应分块策略；最后从噪声抑制、结构保持、空间响应和计算效率四方面进行评价。

3.2　基于 K-SVD 与 OMP 的字典迭代学习去噪方法

传统 K-SVD 与 OMP 压缩感知去噪方法通常采用固定大小的重叠图像块进行字典学习与稀疏重建。K-SVD 通过交替执行稀疏编码与字典原子更新来学习适应样本统计特性的过完备字典，OMP 则在给定字典下逐步选择与残差最相关的原子，从而完成图像块的稀疏表示与重建[6,7,27,28]。该类方法实现相对简单，且具有较好的可解释性，但整幅图像通常只能使用同一种分块尺度：块大小较小时，边缘和纹理保持能力较好，但背景区域噪声抑制不足；块大小较大时，平滑能力增强，但容易造成细小结构模糊。对于同时包含强回声边界、弱回声背景和散斑噪声的超声图像而言，这种固定尺度策略难以兼顾结构保真与噪声平滑。

若将所有图像块按列展开组成样本矩阵 $X=\left[x_1,x_2,\cdots,x_m\right]\in\mathbb{R}^{n\times m}$，字典记为 $D\in\mathbb{R}^{n\times k}$，稀疏系数矩阵记为 $A=\left[a_1,a_2,\cdots,a_m\right]\in\mathbb{R}^{k\times m}$，则传统 K-SVD 去噪模型可写为：

$$\min_{D,A}\left\|X-DA\right\|_F^2\ \text{s.t.}\begin{cases}\left\|a_i\right\|_0\le L\\ i=1,2,\cdots,m\end{cases}\tag{3-1}$$

其中，$\left\|\cdot\right\|_F$ 表示 Frobenius 范数，$\left\|\cdot\right\|_0$ 表示向量的非零元素个数，L 为稀疏度约束。即要求每个图像块在给定字典下能够由尽量少的字典原子进行线性组合表示，并在保持表示稀疏性的同时，使重建误差尽可能小。

在具体实现时，首先随机初始化一个列归一化的过完备字典，随后交替执行稀疏编码与字典更新两个步骤。稀疏编码阶段采用正交匹配追踪算法，对每个图像块逐步选取与当前残差相关性最大的原子。若第 ℓ 次迭代前的残差为 $r_{\ell-1}$，则原子选择过程可写为：

$$I_{\ell}=\underset{\mathrm{j}}{\operatorname{argmax}}\left\{d_{j}^{\mathrm{T}}r_{\ell-1}\right\} \tag{3-2}$$

随后更新残差：

$$r_{\ell}=r_{\ell-1}-a_{I_{\ell}}d_{I_{\ell}} \tag{3-3}$$

直到达到预设稀疏度或残差足够小为止。由此可以得到当前字典下每个图像块的稀疏表示系数。

完成稀疏编码后，K-SVD 算法对字典中的每个原子依次进行更新。对于第 t 个原子 d_t，提取所有使用该原子的图像块索引集合 $\mathcal{I}_t$，构造对应的残差矩阵：

$$R_t=X\left(:,\mathcal{I}_t\right)-DA\left(:,\mathcal{I}_t\right)+d_tA\left(t,\mathcal{I}_t\right) \tag{3-4}$$

再对 R_t 进行奇异值分解：

$$R_t\approx U\Sigma V^{\mathrm{T}} \tag{3-5}$$

并令：

$$\begin{cases} d_t\leftarrow U\left(:,1\right) \\ A\left(t,\mathcal{I}_t\right)\leftarrow\Sigma\left(1,1\right)V\left(:,1\right)^{\mathrm{T}} \end{cases} \tag{3-6}$$

即每次只更新一个字典原子及其对应系数，在保证其余原子不变的条件下尽量减小重建误差。重复执行若干轮后，字典会逐渐适应当前图像块样本的统计特征。单个图像块的字典迭代学习流程如图 3-1 所示。单原子更新只利用当前使用该原子的样本，可避免未激活样本干扰更新方向；列归一化则消除字典原子尺度与稀疏系数幅值之间的不确定性。由此，稀疏编码与字典更新能够在固定另一变量的条件下交替进行，并为不同块尺度独立学习局部统计特征提供统一的求解框架。在这一过程中，残差矩阵仅保留未被当前原子解释的成分，奇异值分解得到的首个左奇异向量对应当前残差能量最大的方向，而首个奇异值与右奇异向量共同修正相关系数。该更新使原子形状与稀疏系数由同一局部残差联合确定，能够减少仅更新原子而保持系数不变所造成的重建偏差。当某原子在本轮未被样本激活时，可保留其当前状态，避免无支撑的更新扰动后续迭代。

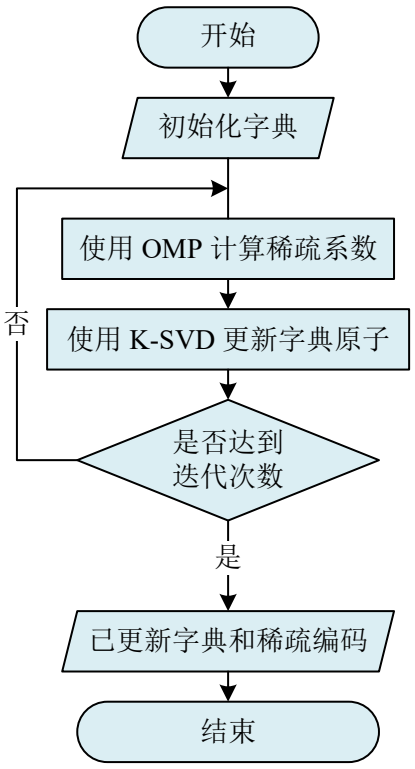


图 3-1　单个图像块的字典迭代学习流程

图像块完成去噪后，需要将所有重建块融合为完整图像。由于相邻图像块通常存在重叠，若直接拼接容易在块边界处产生不连续伪影，因此本文采用归一化加权融合策略进行重建。设第 q 个重建块为 x_q，对应的权重窗函数为 $w_q(i,j)$，则最终输出图像满足：

$$\hat{I}(i,j)=\frac{\sum_q w_q(i,j)\hat{x}_q(i,j)}{\sum_q w_q(i,j)} \tag{3-7}$$

传统固定分块方法实现流程较为简单，通常先将整幅图像划分为相同尺寸的局部图像块，再分别执行稀疏编码、字典学习和块重建操作，最后通过重叠块融合获得完整去噪图像，因此在均匀噪声场景下具有一定去噪能力。然而，该类方法对整幅图像只能采用同一种块大小，难以适应超声图像中背景、边缘、亮点和纹理区域之间显著不同的结构复杂度。对于超声图像而言，平滑背景区域更需要较强的散斑抑制能力，而组织边界、亮点目标和高频纹理区域则更依赖精细尺度的结构保持。当块尺寸较小时，局部结构保持能力较强，边缘和细节不易被过度平滑，但单个块内可利用的统计信息有限，字典学习对背景散斑分布的表征不够充分，背景散斑噪声抑制不足；当块尺寸较大时，块内信息更加充分，噪声抑制能力增强，但不同组

织结构、边缘过渡和亮点响应可能被纳入同一重建单元，导致边界模糊、细节损失和局部响应展宽等问题加重。因此，固定分块方法本质上存在去噪强度与结构保持之间的尺度折中关系，这也构成了后续自适应分块改进的主要切入点。传统固定分块压缩感知去噪流程如图 3-2 所示。这种尺度冲突不仅影响单块重建误差，还会在重叠融合时累积：相邻区域若采用与结构复杂度不匹配的统一尺度，局部细节和平滑背景会受到相同强度的稀疏约束，导致边界附近的估计偏差向周围传播。因此，自适应分块的关键并非简单增加可选尺度数量，而是为每个位置建立与结构先验相对应的尺度选择依据。

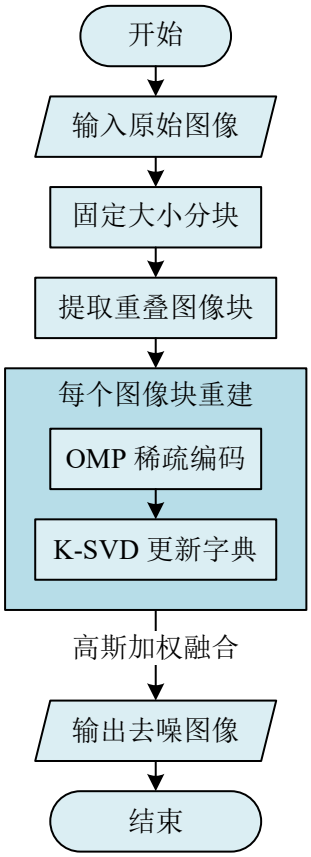


图 3-2　传统固定分块压缩感知去噪流程

3.3　基于 HEVC 块划分的自适应压缩感知去噪方法

第 2 章所得 HEVC 块划分中，小块多对应边缘、亮点和高频纹理，大块多对应平滑背景。本章将其转换为像素级块大小图，并结合插值、灰度放大、离散聚类与多字典重建，使背景区域采用较大尺度抑噪、结构区域采用较小尺度保持细节。完整预处理流程如图 3-3 所示。

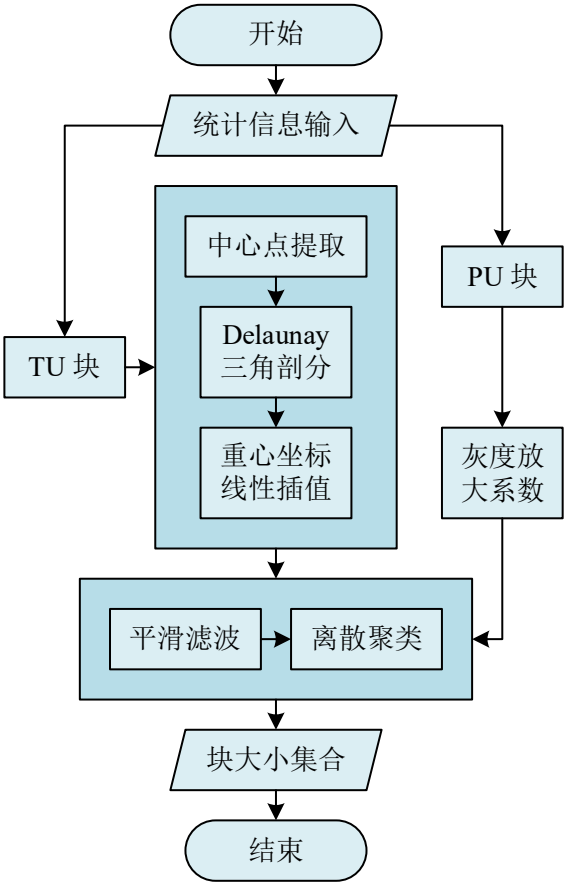


图 3-3　结构先验信息预处理流程

3.3.1　基于 TU 中心点的块大小插值

HEVC 编码器输出的是离散 TU 块信息，每个块仅给出块大小及左上角坐标，因而不能直接作为逐像素去噪所需的块大小图使用。为此，本文首先根据 TU 的左上角坐标和块尺寸提取全部 TU 的中心坐标，并在不同 TU 中心重合时保留较小块，以突出复杂结构区域的精细划分结果，避免较大块尺度掩盖边缘和纹理响应。随后，在这些离散中心点上执行 Delaunay 三角剖分（Delaunay triangulation），将不规则分布的块中心组织为相邻三角形网格，从而为像素级尺度估计提供空间插值基础。对于位于三角形内部的像素点 p，利用重心坐标（barycentric coordinates）进行线性插值，将邻近 TU 中心点的块大小信息连续传播至像素位置，构建像素级块大小图（pixel-wise block-size map）：重心坐标的三个权重之和为 1，且三角形内部各权重非负，因此插值尺度始终位于相邻 TU 尺度范围内，可避免生成缺乏块划分依据的异常极值。

$$\begin{cases} s(p)=\lambda_1 s_1+\lambda_2 s_2+\lambda_3 s_3 \\ \lambda_1+\lambda_2+\lambda_3=1 \end{cases} \tag{3-8}$$

其中，s_1,s_2,s_3 为三角形三个顶点对应 TU 的块大小，$\lambda_1,\lambda_2,\lambda_3$ 为像素点在该三角形中的重心坐标。对于位于凸包外部的像素，则采用最近邻外推。这样即可将离散块划分结果扩展为整幅图像上的像素级块大小图。

3.3.2 基于 PU 灰度的分块放大

仅根据 TU 插值得到的像素级块大小图，虽然能够反映图像局部结构复杂程度，但对暗区、弱回声区域及阴影区域的噪声敏感性考虑仍然不足。超声图像中的低回声背景和阴影区域通常更易受散斑噪声干扰，且这些区域本身灰度较低、有效结构信息较弱，更适合采用较大的重建尺度以增强平滑效果。若仍按照插值得到的小块直接去噪，训练样本的局部性可能限制块内统计信息利用，进而削弱背景散斑噪声抑制能力。为此，本文进一步引入 PU 平均灰度，对插值后的块大小进行自适应放大。设像素 p 所在 PU 的平均灰度为 $\bar{g}_{PU}(p)$，所有 PU 平均灰度的最大值为 $g_{\max}$，原始插值块大小为 $s(p)$，则放大后的块大小记为 $s'(p)$：

$$s'(p)=s(p)\left[1+\alpha\left(1-\frac{\bar{g}_{\mathrm{PU}}(p)}{g_{\max}}\right)^{\gamma}\left(\frac{32}{s(p)}-1\right)\right] \tag{3-9}$$

其中，α 为块尺度放大强度参数，γ 为非线性调节参数。在暗区或弱回声区域，由于 $\bar{g}_{\mathrm{PU}}(p)$ 较小，放大因子相应增大，从而适当提高块大小；在亮区和复杂结构区域，放大幅度则受到抑制。这样既能保留结构复杂区域的小块特征，又能增强平滑背景区域的降噪能力。该灰度调节以预测单元为统计范围，避免仅凭单个像素亮度放大块尺度，从而降低散斑随机波动对尺度选择的直接干扰。

3.3.3 平滑滤波与离散聚类

由于插值和灰度放大过程均为连续浮点运算，所得块大小图中会包含大量非整数尺度值。若直接使用连续块大小进行字典训练和图像块提取，则需要为不同像素位置构建不同尺寸的训练样本和重建块，不仅会显著增加实现复杂度和计算开销，也不利于后续多字典训练与结果融合。因此在放大后、归一化前，先对块大小图施加平滑滤波，以抑制局部尖峰、孤立异常值和尺度突变，使相邻像素的块大小变化更加连续稳定。该步骤能够减少由插值误差或局部块划分突变引起的不规则

分块现象，为后续离散聚类和自适应块大小选择提供更平滑的尺度分布基础，如图 3-4 所示。

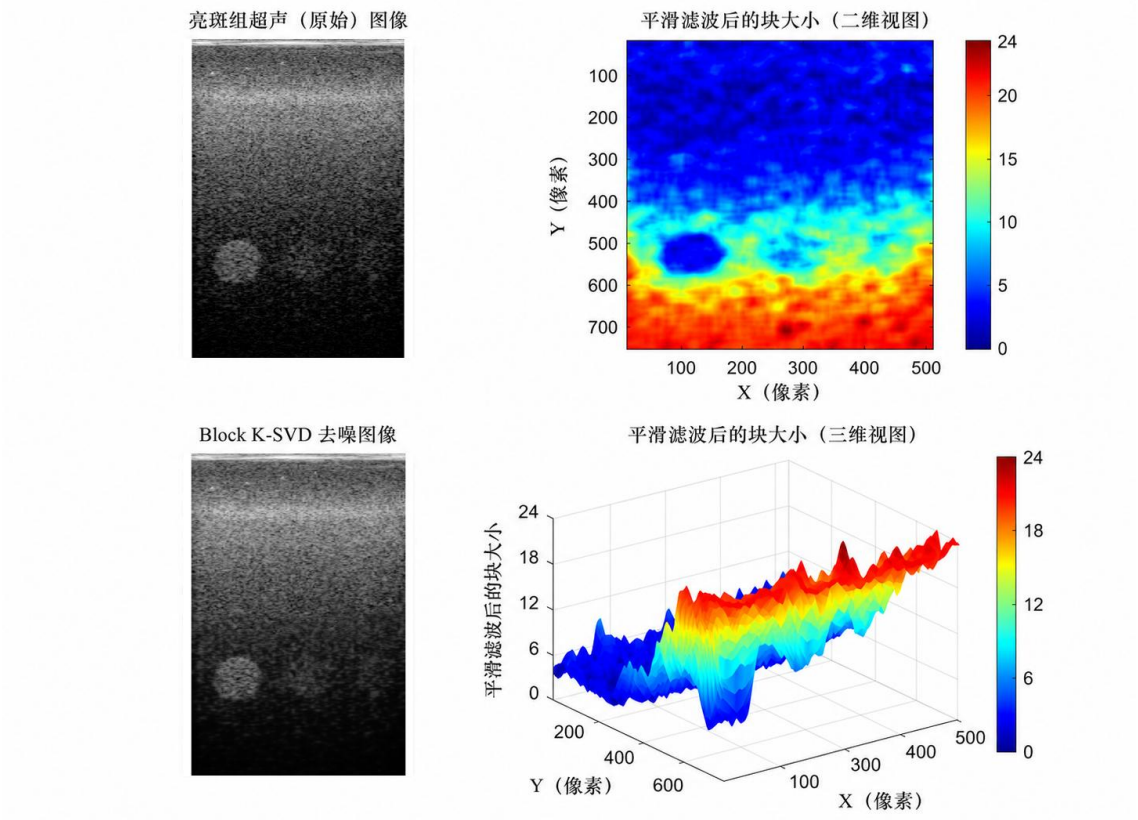


图 3-4　平滑滤波后的块大小三维分布

再将其归一化到$[4-b,4n]$区间，其中b为分块聚类下界调节参数，n为用户定义的块大小层数。归一化后的块大小记为$\tilde{s}(p)$：

$$\tilde{s}(p)=(4-b)+\frac{s'(p)-s'_{\min}}{s'_{\max}-s'_{\min}}\left(4n-(4-b)\right) \tag{3-10}$$

随后再将$\tilde{s}(p)$聚类到离散集合$\{4,8,12,\cdots,4n\}$上，得到最终的像素级块大小图，如图 3-5 所示。即将连续分布的结构先验离散化为有限种块大小类别，方便后续分别训练字典与分组重建。本章独立去噪实验取$n=6$，对应$\{4,8,12,16,20,24\}$六种块大小。该设置覆盖了从小尺度结构保持到大尺度背景平滑的完整候选范围，既便于与 Conv. 4×4 至 Conv. 24×24 固定分块方案保持一致的尺度对照，也使 Block K-SVD 能够在边缘纹理保持和散斑噪声抑制之间进行充分的自适应选择。将连续尺度映射到有限集合后，同一类别可共享块尺寸、训练样本组织方式和字典结构，从而把

连续先验转化为可执行的分组重建条件。同时，离散类别的上、下界均由预设尺度集合限定，连续尺度的小幅波动不会产生新的字典分支，有助于保持训练样本量在各尺度之间的可控分配。

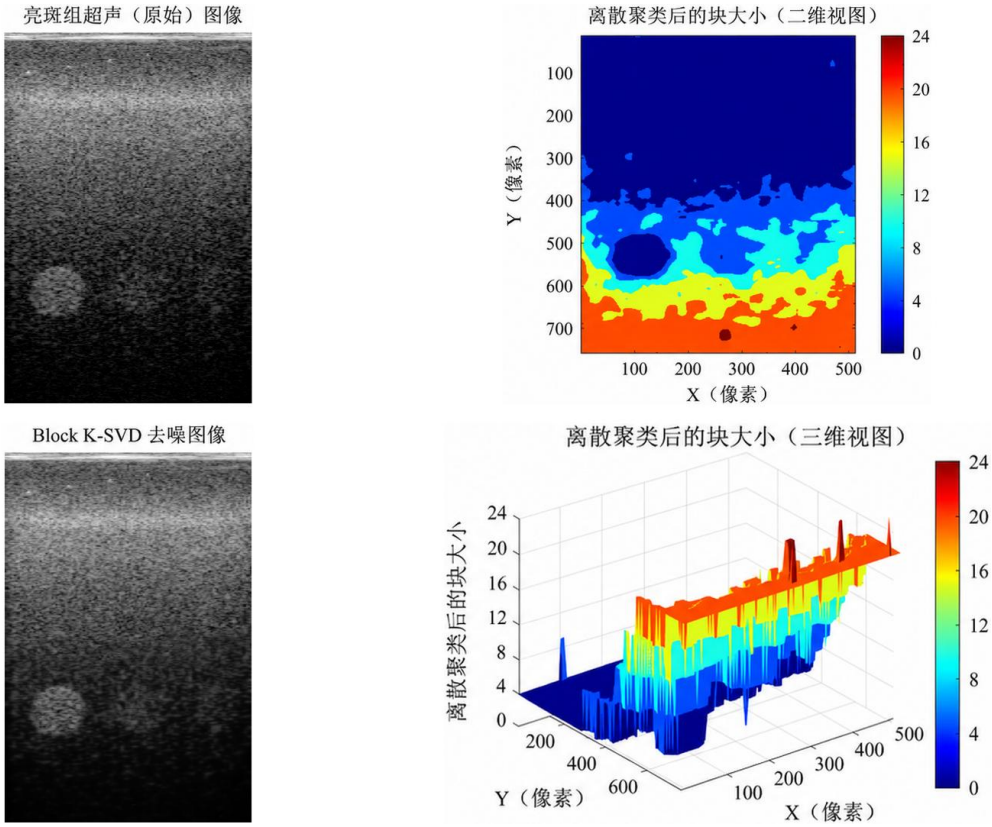


图 3-5　离散聚类后的块大小三维分布

3.3.4　多字典融合去噪

得到离散块大小图后，本文不再对整幅图像训练单一字典，而是按各活跃块大小分别提取图像块、分别训练对应字典。设属于块大小 b 的样本集合为 X_b，其对应字典和稀疏系数分别为 D_b 与 A_b，则每一类块大小都独立求解：

$$\min_{D_b,A_b}\left\|X_b-D_bA_b\right\|_F^2 \ \text{s.t.}\ \left\|a_i^{(b)}\right\|_0\le L \tag{3-11}$$

这一策略的优势在于：不同尺度的局部纹理可由具有不同统计特性的字典来表征，从而避免单一字典同时拟合平滑背景与复杂细节时产生表达能力不足的问题。对于较小块，训练样本更多来自边缘、亮点和高频纹理区域，字典原子更偏向描述局部突变、方向性结构和细粒度灰度变化；对于较大块，训练样本则更多覆盖

平滑背景和低频结构，字典原子更适合表征均匀区域内的散斑分布和缓慢灰度变化。由此，不同块大小对应的字典能够分别承担结构保持与噪声抑制功能，使重建过程更符合超声图像的局部结构差异。重建时，为了减弱块效应并降低相邻重建块之间的边界不连续，本文继续采用高斯加权融合。若块大小为b，则对应高斯窗（Gaussian window）权重为：

$$w_b\left(i,j\right)=\mathrm{e}^{-\frac{(i-c)^2+(j-c)^2}{2(\eta b)^2}} \tag{3-12}$$

其中，c为块中心位置，η为高斯窗尺度比例参数。即图像块中心处权重较大，边缘处权重较小，从而使重叠区域的融合更加平滑。

综合上述步骤，第 2 章的 HEVC 结构先验被转化为压缩感知去噪中的像素级尺度约束。与全图使用单一块大小不同，所提方法在感兴趣区域保持较小重建尺度，在背景区域采用较大尺度，以兼顾结构保真和散斑抑制。整体流程如图 3-6 所示。

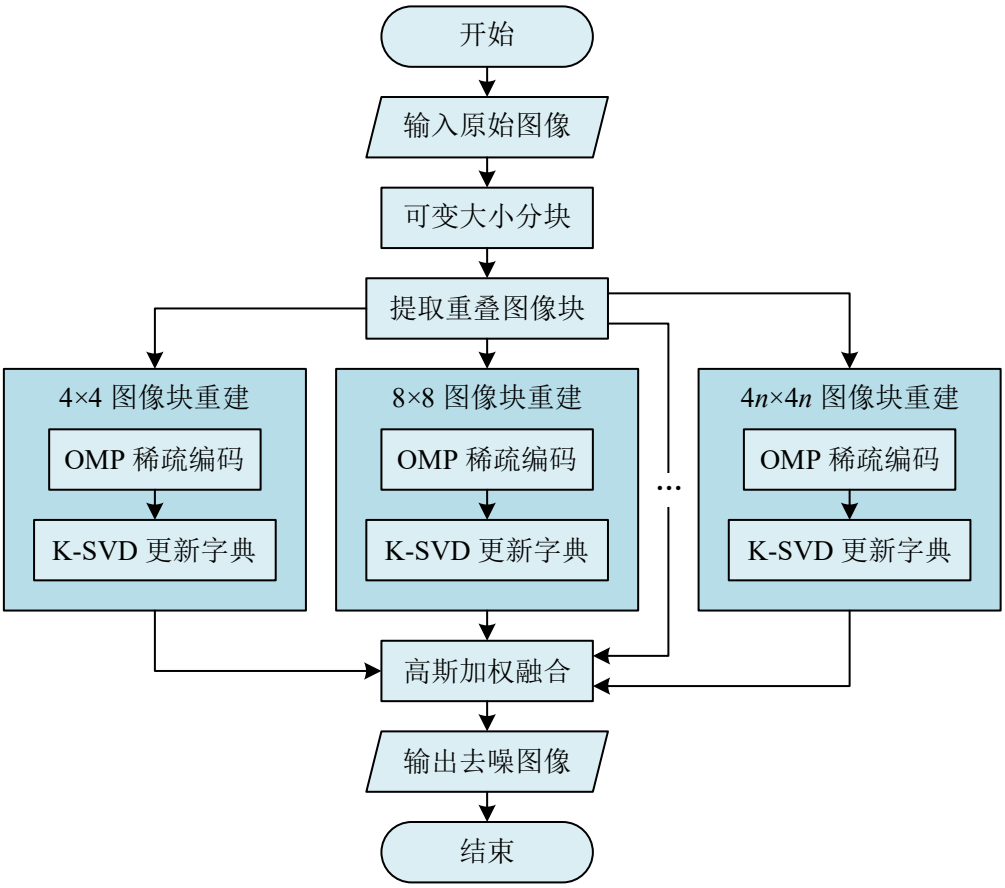


图 3-6　改进后的自适应分块压缩感知去噪流程

3.4 评价指标与结果分析

为评价自适应分块压缩感知去噪性能，本章从噪声抑制、结构保持、空间分辨率保持和计算效率四个维度开展分析。考虑到超声图像缺少理想无噪声参考，评价同时采用无参考统计指标和以原始图像为参照的结构指标。评价时各指标均在相同测试图像、相同感兴趣区域和相同实现环境下计算，以避免图像内容或计时范围差异掩盖分块策略本身的影响。量化结果与局部视觉对比共同用于判断结构保持和噪声抑制是否协调。

3.4.1 评价指标

对比度噪声比（Contrast-to-Noise Ratio，CNR）用于评价目标区域与背景区域之间的灰度可分性及噪声波动影响。本章采用全图灰度均值与标准差的比值作为近似无参考统计量，定义为：

$$\mathrm{CNR}=\frac{\mu}{\sigma} \tag{3-13}$$

其中，μ 为图像像素平均值，σ 为像素标准差。CNR 越大，表明图像灰度均值相对于整体波动越高，噪声扰动相对越小。

等效视数（Equivalent Number of Looks，ENL）用于评价斑点噪声平滑程度。定义为：

$$\mathrm{ENL}=\frac{\mu^2}{\mathrm{Var}} \tag{3-14}$$

其中，Var 为图像像素方差。ENL 越大，表明均匀区域越平滑，去噪算法对噪声的抑制能力越强。

边缘保持指数（Edge Preservation Index，EPI）用于衡量去噪前后边缘梯度的一致性。本文先采用 Sobel 算子计算原始图像和去噪图像的梯度幅值，再计算二者的相关系数：

$$\mathrm{EPI}=\mathrm{corr}\left(\nabla I_{\mathrm{orig}},\nabla I_{\mathrm{den}}\right) \tag{3-15}$$

EPI 越接近 1，说明去噪后边缘结构保持得越好。

特征相似性指数（Feature Similarity Index，FSIM）用于综合评价去噪前后图像在梯度幅值和相位一致性方面的相似程度。若梯度幅值相似性和相位一致性相似性分别记为 S_{GM} 与 S_{PC}，最大相位一致性图记为 PC_{m}，则 FSIM 定义为：

$$\mathrm{FSIM}=\frac{\sum S_{\mathrm{GM}}S_{\mathrm{PC}}\mathrm{PC}_{\mathrm{m}}}{\sum \mathrm{PC}_{\mathrm{m}}} \tag{3-16}$$

FSIM 越接近 1，说明去噪结果对原始结构特征的保持越充分。

半高全宽（Full Width at Half Maximum，FWHM）用于表征亮点目标的空间响应宽度，可作为空间分辨率保持能力的辅助评价指标。其测量过程如下：首先在预定义矩形 ROI 内提取亮度值不低于该区域最大值 90%的像素，并以灰度加权质心（intensity-weighted centroid）作为目标中心；然后分别沿水平（x）和垂直（y）方向提取穿过该质心的一维灰度剖面 $f(t)$；最后采用线性插值确定剖面达到峰值一半处的左右交点 t_{L} 和 t_{R}，并据此计算半高全宽：

$$\mathrm{FWHM}=t_{\mathrm{R}}-t_{\mathrm{L}}\ \text{s.t.}\ f(t_{\mathrm{L}})=f(t_{\mathrm{R}})=\frac{1}{2}\max f(t) \tag{3-17}$$

FWHM 值越接近原始图像，表明去噪方法在抑制噪声的同时能够较好保留亮点目标的空间响应宽度，即对目标空间分辨率的保持效果越好。若 FWHM 值显著增大，则说明去噪结果中的亮点轮廓发生展宽，可能由过度平滑或局部结构扩散引起，表明该方法在降低噪声的同时削弱了小尺度目标的边界清晰度和空间定位能力。

去噪用时用于评价各方法的计算效率。定义为单张图像从去噪开始到输出完成的实际处理时间，其中包括字典训练、OMP 稀疏编码和图像重建过程。传统固定块大小方法在 4×4、8×8、12×12、16×16、20×20、24×24 每种块大小下各独立执行一次，共 6 次；Block K-SVD 依据 HEVC 分块映射对不同区域采用对应块大小进行字典训练与重建，仅运行一次。

除整张图像的前四个指标外，本文还进一步结合聚类后的块大小图，统计不同块大小所覆盖区域中的平均评价指标。对于存在区域重叠的位置，采用与重建阶段一致的高斯权重进行加权融合。即若某一块大小类别对应区域记为 Ω_b，评价量图记为 $Q(p)$，则该类别的区域平均评价值可写为：

$$\bar{Q}_b=\frac{\sum_{p\in\Omega_b} w_b(p)Q(p)}{\sum_{p\in\Omega_b} w_b(p)} \tag{3-18}$$

这样既可以从整体层面评价整幅图像的综合去噪效果，也可以从局部层面分析不同块大小区域对各项指标的贡献，从而更清晰地判断自适应分块策略在背景平滑、边缘保持和细节恢复中的作用。其中，全局指标用于判断整幅图像的总体变化，区域加权结果用于定位不同尺度类别的贡献；只有两者趋势相互印证时，才将性能差

异归因于尺度分配策略，而不将个别区域的偶然波动外推为整体结论。分子与分母采用相同高斯权重归一化，可减小区域重叠次数差异对统计值的影响。

3.4.2 结果分析

为便于表述，将 4×4 至 24×24 固定分块压缩感知去噪方法记为 Conv. 4×4 至 Conv. 24×24，将自适应方法记为 Block K-SVD。各方法在全部测试图像上独立计算指标并取平均，结果见表 3-1。

表 3-1 测试集全体图像的平均评价指标

测试组	CNR	ENL	EPI	FSIM
Conv. 4×4	1.299798	1.722878	0.984678	0.984552
Conv. 8×8	1.331917	1.809789	0.862687	0.889120
Conv. 12×12	1.357129	1.879606	0.714499	0.789500
Conv. 16×16	1.372105	1.921968	0.604759	0.716314
Conv. 20×20	1.382041	1.950719	0.518648	0.660669
Conv. 24×24	1.389046	1.971147	0.454159	0.619583
Block K-SVD	**1.317275**	**1.770189**	**0.918617**	**0.932873**
超声原始图像	1.286885	1.688649	1.000000	1.000000

由表 3-1 可见，随着传统固定块大小由 4×4 增至 24×24，CNR 与 ENL 总体呈上升趋势，表明较大分块能够利用更大范围内的局部统计信息，从而增强散斑噪声平滑效果。然而，随着分块尺度持续增大，EPI 和 FSIM 均呈下降趋势，说明边缘、纹理和局部结构信息在重建过程中更容易被平滑削弱。以 24×24 方案为例，其 CNR 和 ENL 分别为 1.389046 和 1.971147，为固定分块方案中的最高值，但 EPI 和 FSIM 分别降至 0.454159 和 0.619583，说明该方案虽然具有较强噪声抑制能力，但边缘与纹理保持能力相对较弱。

Block K-SVD 的 CNR 和 ENL 分别为 1.317275 和 1.770189，较原始图像分别提高 2.36%和 4.83%，表明该方法在结构自适应处理条件下仍具备一定噪声抑制能力。与传统 8×8 方法相比，其 CNR 和 ENL 略低，但 EPI 和 FSIM 分别提高约 6.98%和 5.26%，说明该方法在结构保持方面具有更明显优势。这一结果表明，自适应分块策略并非以单一固定块大小替代整幅图像处理，而是根据局部结构复杂度分配不同处理尺度，在复杂结构区域保留较小块、在平滑区域采用较大块，从而在保持一定噪声抑制能力的同时提高结构保持相关指标。

为比较不同结构类型下的表现，按照亮带、亮斑、亮点、空洞和沟壑 5 组分别统计 Block K-SVD 的平均指标，结果见表 3-2。该分组可反映方法对连续强回声、小尺度亮点、局部高亮斑块、低回声空洞和沟壑状纹理的适应差异。统一分组口径有助于避免总体均值掩盖类别间的结构响应差异。

表 3-2　各类测试图像中 Block K-SVD 的平均去噪评价指标

测试组	CNR	ENL	EPI	FSIM
亮带组	1.330492	1.777620	0.878780	0.912297
亮斑组	1.179921	1.406060	0.922107	0.932005
亮点组	1.133053	1.296912	0.937959	0.938671
空洞组	1.386137	1.934916	0.937771	0.943994
沟壑组	1.556772	2.435438	0.916470	0.937399

结合表 3-2 可见，不同类别图像的自适应去噪结果存在一定差异，说明图像结构类型会影响 Block K-SVD 的局部重建效果。沟壑组和空洞组的 CNR 与 ENL 相对较高，表明该类图像中较大面积平滑或低回声区域更适合采用较大块进行背景抑噪；亮点组、空洞组和亮斑组的 EPI 与 FSIM 相对较高，表明该方法对小目标边缘、亮点边界和局部纹理的保持能力相对较好。该结果与第 2 章获得的结构先验信息基本一致，即结构复杂区域倾向于对应较小分块，结构较简单区域倾向于对应较大分块，从而验证了结构先验引导自适应去噪的合理性。在统一评价口径下，类别间差异主要反映图像结构组成及其对应尺度分布的不同，因此可进一步检验结构先验与局部重建尺度之间的匹配关系。CNR 与 ENL 侧重背景统计稳定性，EPI 与 FSIM 侧重结构相似性，分组联合分析可避免将单一类别中的较强平滑效果直接解释为整体性能优势。

进一步利用 FWHM 定量评价亮点目标的空间响应保持能力：在感兴趣区域内定位灰度加权质心，提取水平和垂直剖面，并以亚像素线性插值计算半高全宽。亮带在水平方向贯穿感兴趣区域，FWHM-x 无区分意义，因此仅报告亮带 FWHM-y；亮点组同时报告两个方向，结果见表 3-3。

表 3-3　亮带组与亮点组 ROI 平均 FWHM 统计结果

测量方向	Conv. 4×4	Conv. 24×24	Block K-SVD	*原始图像*
FWHM-x	18.227252	20.366071	**17.446841**	*17.652963*
FWHM-y	12.933793	12.959050	**12.940591**	*13.015497*

为直观展示感兴趣区域内亮点空间响应，绘制各区域的水平与垂直亮度剖面，如图 3-7 所示。左侧标出区域位置，右侧给出一维剖面对比；曲线越接近原始图像，说明空间响应保持越好。

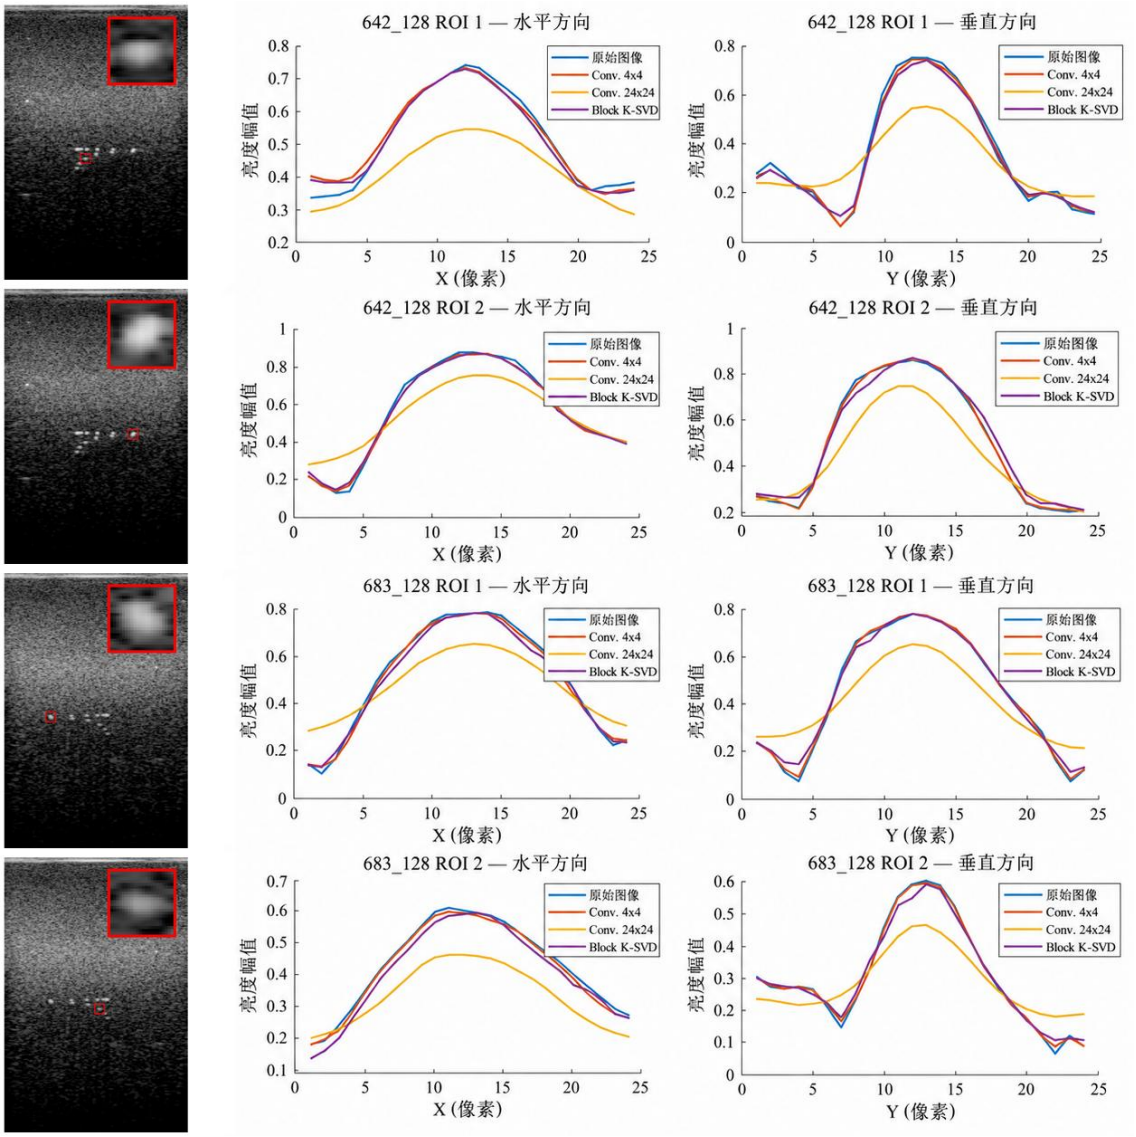


图 3-7　亮点组各 ROI 的 FWHM 测量亮度剖面对比

由图 3-7 可见，亮点组 4 个 ROI 中的亮点目标在水平和垂直两个方向上均呈现有限宽度峰形，因此 FWHM-x 与 FWHM-y 均具有区分意义。在水平方向上，Block K-SVD 的剖面与原始图像最为接近，其 FWHM-x 均值为 17.446841 像素，较原始值 17.652963 像素偏差约为 1.17%；Conv. 4×4 的 FWHM-x 为 18.227252 像素，已出现轻微展宽；Conv. 24×24 的 FWHM-x 增至 20.366071 像素，展宽现象更

为明显。在垂直方向上，根据表 3-3 中全部 ROI 的平均结果，Block K-SVD 的 FWHM-y 为 12.940591 像素，较原始图像的 13.015497 像素偏差较小；Conv. 4×4 和 Conv. 24×24 的 FWHM-y 分别为 12.933793 像素和 12.959050 像素，也与原始图像较接近。总体而言，Block K-SVD 的 FWHM-x 和 FWHM-y 与原始图像保持较好一致性，尤其在水平方向上未出现明显目标展宽。相比之下，传统固定块大小方法，尤其是较大分块方案，更易出现目标展宽现象。

在同一台计算机的 MATLAB R2024b 环境下，统计 40 张测试图像的完整去噪用时，涵盖样本构建、字典训练、OMP 稀疏编码、块重建与融合。固定分块方法分别运行 6 种块大小，Block K-SVD 按自适应映射运行一次，平均用时见表 3-4。

表 3-4　各去噪方法单张图像平均处理时间

去噪方法	平均用时	去噪方法	平均用时
Conv. 4×4	35.90 秒	Conv. 20×20	85.60 秒
Conv. 8×8	42.80 秒	Conv. 24×24	104.10 秒
Conv. 12×12	55.70 秒	**Block K-SVD**	**320.00 秒**
Conv. 16×16	69.50 秒	*传统方法合计*	*393.60 秒*

从计算效率看，传统固定块大小方法的单次去噪用时随块大小增加而上升，其中 4×4 方案平均耗时 35.90 秒，24×24 方案平均耗时 104.10 秒。这主要是因为大尺寸图像块对应更高维的块向量、更复杂的字典学习过程和更大的 OMP 稀疏编码计算量，同时也会增加图像块提取、样本矩阵构建和重叠融合过程中的计算负担。若遍历全部 6 种固定块大小，传统方法总耗时约为 393.60 秒；相比之下，Block K-SVD 单张图像平均耗时为 320.00 秒，较前者缩短约 18.72%。这是因为 Block K-SVD 依据 HEVC 块划分映射，对不同区域分别执行对应块大小的训练与重建，避免了对整幅图像重复进行多次完整处理，并减少了无关尺度下的冗余计算。尽管 Block K-SVD 单次运行时间仍高于任一单一固定块大小方案，但其 EPI、FSIM 和 FWHM 结果更接近原始图像，说明该方法在计算开销与结构保持性能之间取得了较为合理的平衡。其中，18.72%以遍历六种固定尺度的总耗时为参照，并不表示自适应方法快于任一单尺度运行；该比较对应获得多尺度选择能力所需的总体计算代价。

以亮带组图像 837_128.tif 分析不同块大小区域的指标贡献，如图 3-8 所示。小块区域的 EPI 和 FSIM 较高，更利于保持边缘与纹理；大块区域的 CNR 和 ENL 较

高，更利于平滑背景。多尺度字典协同融合因而能够在同一图像中兼顾结构保持与噪声抑制。

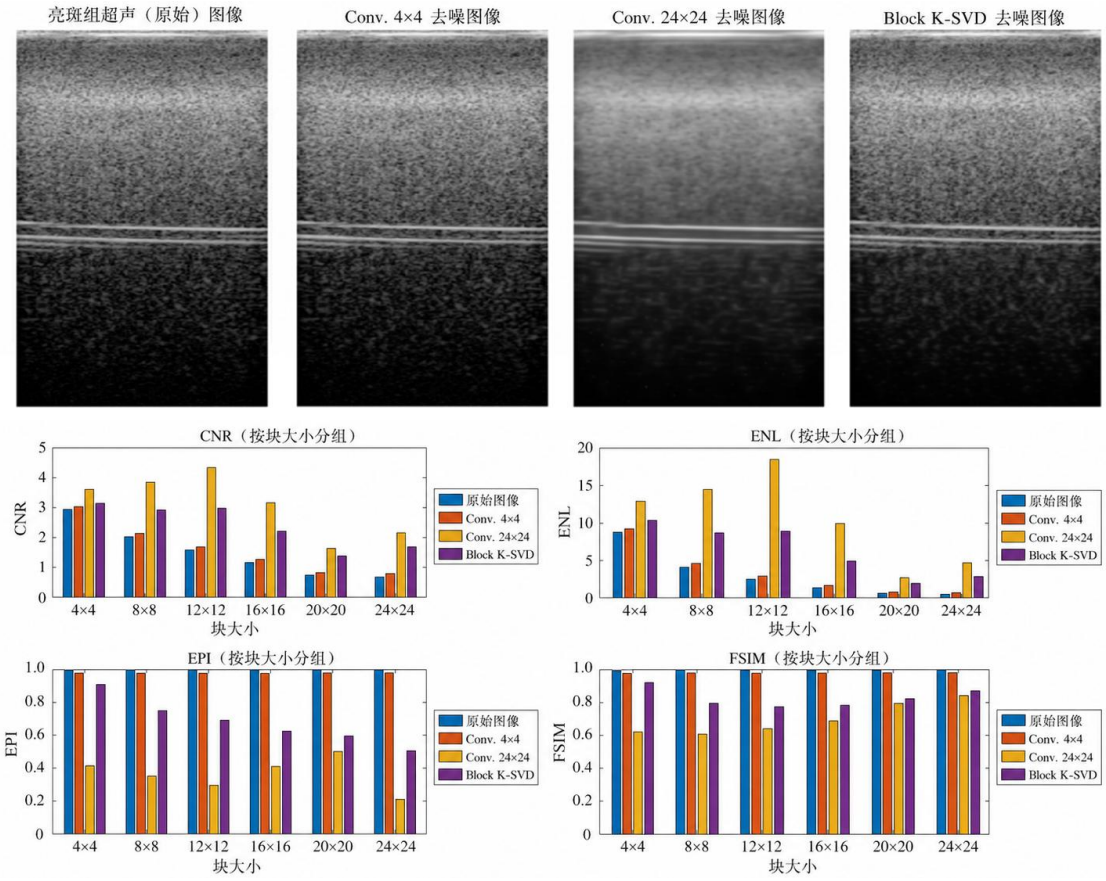


图 3-8　亮带组 837_128.tif 按块大小分组的评价指标

单一指标难以完全反映视觉质量，因此从每组测试图像中选取 1 张代表样本进行主观比较，如图 3-9 所示。结果与定量指标一致：亮带和亮斑轮廓较完整，亮点目标仍可辨识，空洞与沟壑区域的散斑减弱且灰度过渡更稳定。该主观比较用于核对指标所反映的结构变化，不替代 CNR、EPI、FSIM 与 FWHM 等定量评价。比较时重点观察边界连续性、亮点轮廓宽度、背景散斑颗粒和灰度过渡，使视觉现象能够与噪声抑制、结构保持及空间响应指标相互对应。代表图像同时包含亮带、亮斑、亮点、空洞和沟壑等典型结构，可在同一处理口径下观察不同区域对尺度选择的响应。若背景散斑明显减弱而亮点轮廓仍集中，说明平滑并未以显著扩展点目标为代价；若空洞和沟壑内部灰度更稳定且边界位置基本保持，则说明较大块与较小块分别承担了背景抑噪和结构保护作用。该观察范围与前述分组指标相对应，可用

于发现平均值可能掩盖的局部异常。因此，主观观察仅用于解释指标变化的空间来源，并需与同一图像的定量结果交叉核对。

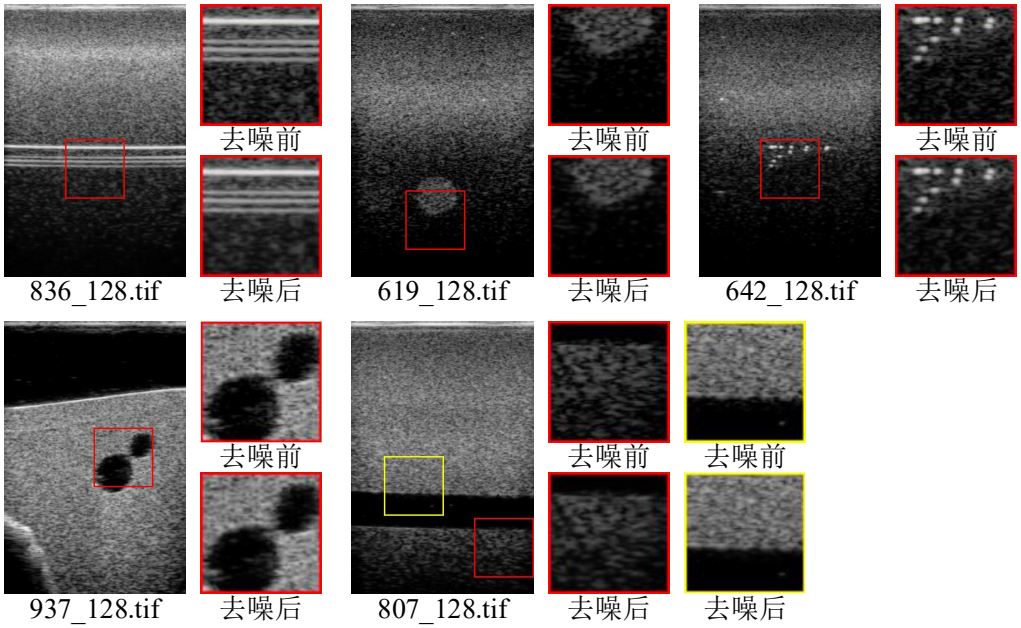


图 3-9　测试集代表性图像去噪前后的局部放大对比

综合结果表明，固定分块存在明确的尺度折中：小块利于细节保持，大块利于背景抑噪。Block K-SVD 通过结构先验解析、灰度调节、平滑聚类和分组字典重建，为不同区域分配相应尺度，在保持一定噪声抑制能力的同时提高结构保持指标。

3.5　本章小结

本章将第 2 章的 HEVC 块划分先验引入 K-SVD 与 OMP 去噪。固定分块方法只能在全图采用单一尺度，因而难以同时满足平滑背景抑噪和复杂结构保持。

所提 Block K-SVD 先通过变换单元中心插值构建像素级块大小图，再依据预测单元平均灰度调节暗区尺度，并经平滑与离散聚类得到有限块大小；不同尺度分别训练字典、执行稀疏重建，最后以高斯权重融合。

实验中，Block K-SVD 的 CNR 和 ENL 分别为 1.317275 和 1.770189，较原始图像提高 2.36%和 4.83%；相较固定 8×8 方法，EPI 和 FSIM 提高 6.98%和 5.26%，亮点 FWHM 更接近原始图像。其平均用时为 320.00 秒，较遍历 6 种固定块大小的总耗时缩短 18.72%，表明结构先验能够在去噪强度、结构保持和计算开销之间形成较合理的平衡。

第 4 章　超声超分辨率成像 USR-Mamba 网络研究

4.1　引言

医学超声 B 模式图像超分辨率可表述为低波束线数到高波束线数的图像映射。为同时恢复组织轮廓、散斑纹理和亮点空间响应，本章设计 USR-Mamba 网络，在编码器—高分辨率瓶颈—解码器框架中结合空间—频率双域状态空间建模、残差卷积细化和角向均匀扫描。

4.2　超声超分辨率成像 USR-Mamba 网络设计

超声超分辨率任务可以视为从低分辨率观测恢复高分辨率图像的图像到图像映射问题。设低分辨率超声图像为 I_{LR}，高分辨率标签图像为 I_{HR}，上采样算子为 $U(\cdot)$。为便于分模块描述，本文将网络整体计算过程拆分为输入变换、编码器、瓶颈模块和解码器四个部分。

首先，将低分辨率输入上采样至目标尺寸，并通过编码器提取中间特征：

$$\begin{cases} X = U\left(I_{\mathrm{LR}}\right) \\ \left(f_1, \{s_l\}_{l=1}^{L}\right) = E\left(X\right) \end{cases} \tag{4-1}$$

其中，X 表示进入网络的输入图像，$E(\cdot)$ 表示编码器，f_1 表示进入瓶颈部分的主干特征，$\{s_l\}_{l=1}^{L}$ 表示编码器保留的跳连特征集合。若预处理阶段已经得到与目标尺寸一致的输入图像，也可直接令 $X = I_{\mathrm{LR}}^{\mathrm{up}}$。该处理统一了不同预处理路径的输入尺寸，使后续网络结构能够集中建模特征表达差异，而不需额外区分空间尺寸。

随后，瓶颈模块对主干特征进行多阶段上下文建模。设瓶颈部分共有 J 个阶段，第 j 个阶段的特征更新过程写为：

$$\begin{cases} \tilde{f}_j = \begin{cases} \mathcal{D}_j\left(f_j\right), j \in S \\ f_j, j \notin S \end{cases} \\ \begin{cases} f_{j+1} = \mathrm{rCNN}_j\left(\tilde{f}_j\right) \\ j = 1, 2, \cdots, J \end{cases} \end{cases} \tag{4-2}$$

其中，$\mathcal{D}_j(\cdot)$ 表示第 j 阶段的双域 SSM 模块，$\mathrm{rCNN}_j(\cdot)$ 表示第 j 阶段的残差 CNN 模块，S 表示插入双域 SSM 模块的阶段索引集合。结合本文实现结构，可取 $J = 9$，

并令 $S=\{1,5,9\}$，即在第 1、5、9 个瓶颈阶段引入双域建模，以在上下文表达能力与计算复杂度之间取得平衡。

在引入双域 SSM 的阶段中，网络分别在图像域和傅里叶域提取上下文特征。对输入特征 f_j，双域模块可表示为：

$$\begin{cases} u_I = \mathcal{M}_{I,j}\left(f_j\right) \\ u_F = \mathcal{F}^{-1}\left(\mathcal{R}^{-1}\mathcal{M}_{F,j}\left(\mathcal{R}\left(\mathcal{F}\left(f_j\right)\right)\right)\right) \\ \mathcal{D}_j\left(f_j\right) = P_j\left(\left[u_I;u_F\right]\right) \end{cases} \tag{4-3}$$

其中，$\mathcal{M}_{I,j}(\cdot)$ 和 $\mathcal{M}_{F,j}(\cdot)$ 分别表示图像域 SSM 分支和傅里叶域 SSM 分支；$\mathcal{F}(\cdot)$ 和 $\mathcal{F}^{-1}(\cdot)$ 分别表示傅里叶变换与傅里叶逆变换；$\mathcal{R}(\cdot)$ 表示将复数频谱特征的实部与虚部沿通道维拼接，$\mathcal{R}^{-1}(\cdot)$ 表示将其重新组合为复数形式；$[u_I;u_F]$ 表示通道维拼接；$P_j(\cdot)$ 表示通道投影操作，用于将双分支融合后的特征恢复至目标通道数。

对任一分支，若其输入记为 q，则分支内部的线性映射、局部卷积、SSM 建模与通道混合过程可统一写为：

$$\begin{cases} g = \sigma\left(\mathrm{Lin}_{\beta}\left(q\right)\right) \\ e = \sigma\left(\mathrm{DWConv}\left(\mathrm{Lin}_{\beta}\left(q\right)\right)\right) \\ M = \mathrm{SSM}_{\theta}\left(e\right) \\ e_{\mathrm{SSM}} = q + \mathrm{Lin}_{1/\beta}\left(g \odot M\right) \\ \mathcal{M}_{*,j}\left(q\right) = \mathrm{cmConv}\left(e_{\mathrm{SSM}}\right) + \mathrm{Conv}\left(e_{\mathrm{SSM}}\right) \\ * \in \{I,F\} \end{cases} \tag{4-4}$$

其中，$\mathrm{Lin}_{\beta}(\cdot)$ 表示带通道扩展系数 β 的线性映射，$\mathrm{Lin}_{1/\beta}(\cdot)$ 表示通道压缩映射，$\mathrm{DWConv}(\cdot)$ 表示深度卷积，$\sigma(\cdot)$ 表示激活函数，$\odot$ 表示逐元素乘法，$\mathrm{cmConv}(\cdot)$ 表示通道混合卷积，$\mathrm{SSM}_{\theta}(\cdot)$ 表示基于角向均匀扫描的状态空间算子。对于图像域分支，$q=f_j$；对于傅里叶域分支，$q=\mathcal{R}\left(\mathcal{F}\left(f_j\right)\right)$。

最后，解码器将瓶颈输出特征与编码器浅层细节特征融合，并映射为高分辨率重建结果：

$$\hat{I}_{\mathrm{HR}} = D\left(f_{J+1},\{s_l\}_{l=1}^{L}\right) \tag{4-5}$$

其中，$D(\cdot)$ 表示解码器，$\hat{I}_{\mathrm{HR}}$ 表示 USR-Mamba 输出的超分辨率重建图像。

上述式(4-1)至式(4-5)给出了 USR-Mamba 的整体数据流。与仅依赖局部卷积的网络不同，该结构在保持较高空间分辨率的前提下，通过双域 SSM 增强全局上下文建模能力，再利用残差 CNN 补偿局部细节，从而适应超声图像局部散斑密集、全局组织结构连续以及高低频信息并存的成像特点。USR-Mamba 网络整体结构如图 4-1 所示。

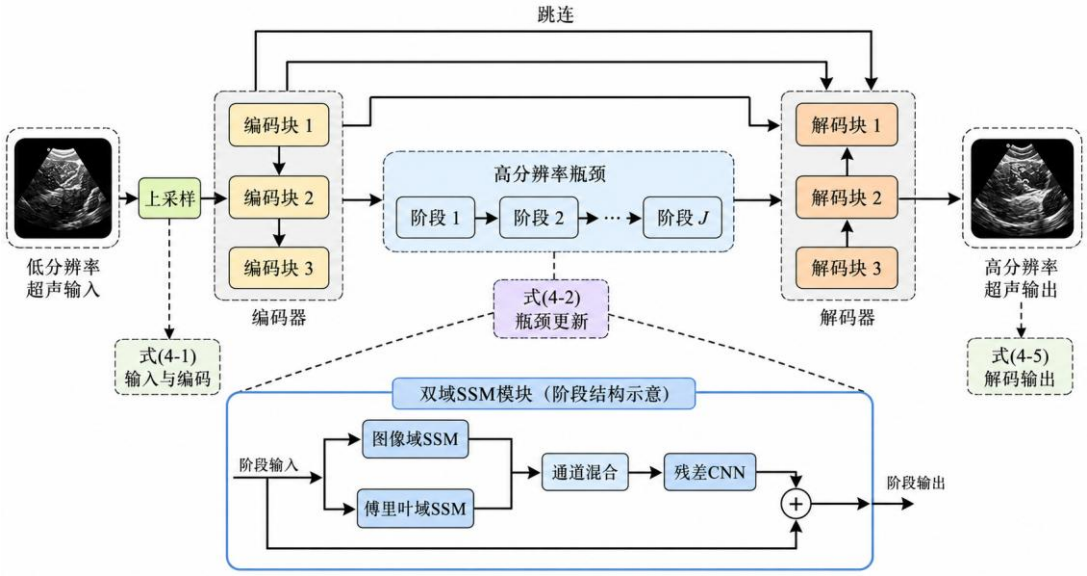


图 4-1　USR-Mamba 网络整体结构

4.2.1　基于双域 SSM 的超分辨率网络架构

传统 CNN 擅长提取局部边缘与纹理，但有效感受野受卷积核、深度和下采样限制，对远距离组织轮廓及跨区域散斑关系建模不足；Transformer 虽具全局建模能力，在高分辨率特征上计算与显存开销较大。为兼顾上下文范围和效率，本章在高分辨率瓶颈中引入状态空间模块，并设置图像域与傅里叶域双分支，分别建模空间结构和频谱分布。

USR-Mamba 由编码器、高分辨率瓶颈和解码器组成。编码器提取灰度、散斑和边缘特征；瓶颈在较高空间尺度上聚合图像域与频率域上下文；解码器融合深层与跳连特征，恢复边界、亮点和细粒度纹理。瓶颈阶段保留较高分辨率，可减少弱小目标和局部位置信息在深层建模中的损失。

编码器主要由多个 CNN 块组成，每个 CNN 块包括卷积层、批归一化（Batch Normalization，BN）和线性整流单元（Rectified Linear Unit，ReLU）激活函数。卷

积层用于提取超声图像中的局部边缘、灰度过渡和散斑纹理等低层信息；BN 用于缓解训练过程中的特征分布变化；ReLU 用于增强网络的非线性表示能力。编码器输出的主干特征 f_1 和跳连特征 $\{s_l\}_{l=1}^{L}$ 分别承担深层建模和浅层细节补偿两类作用，其定义见式(4-1)。

瓶颈部分由多个连续阶段组成，整体更新形式见式(4-2)。其中，双域 SSM 模块仅插入于少数关键阶段，用以增强长距离依赖建模能力；其余阶段主要通过残差 CNN 维持局部结构表达。这样设计的原因在于，若在所有阶段均使用复杂的双域建模，会显著增加计算开销，而仅在关键位置插入双域 SSM 则能够更有效地补充全局上下文信息。

双域 SSM 模块的核心思想是同时在图像域和傅里叶域对中间特征进行建模，其计算形式如式(4-3)所示。图像域分支直接作用于空间特征图，重点学习组织边界、局部纹理以及远距离结构之间的空间关联；傅里叶域分支则先将特征映射到频率域，再对实部和虚部进行通道拼接，随后执行 SSM 建模，最后通过反变换返回图像域。引入傅里叶域分支的原因在于，低频成分更能反映整体亮度和缓慢变化区域，高频成分则更多对应边界、亮点目标和细小纹理。若仅在图像域建模，网络对频谱结构的表达能力有限；若仅在频域建模，则可能削弱空间定位能力。双域建模有助于利用两类信息的互补性，其模块结构如图 4-2 所示。

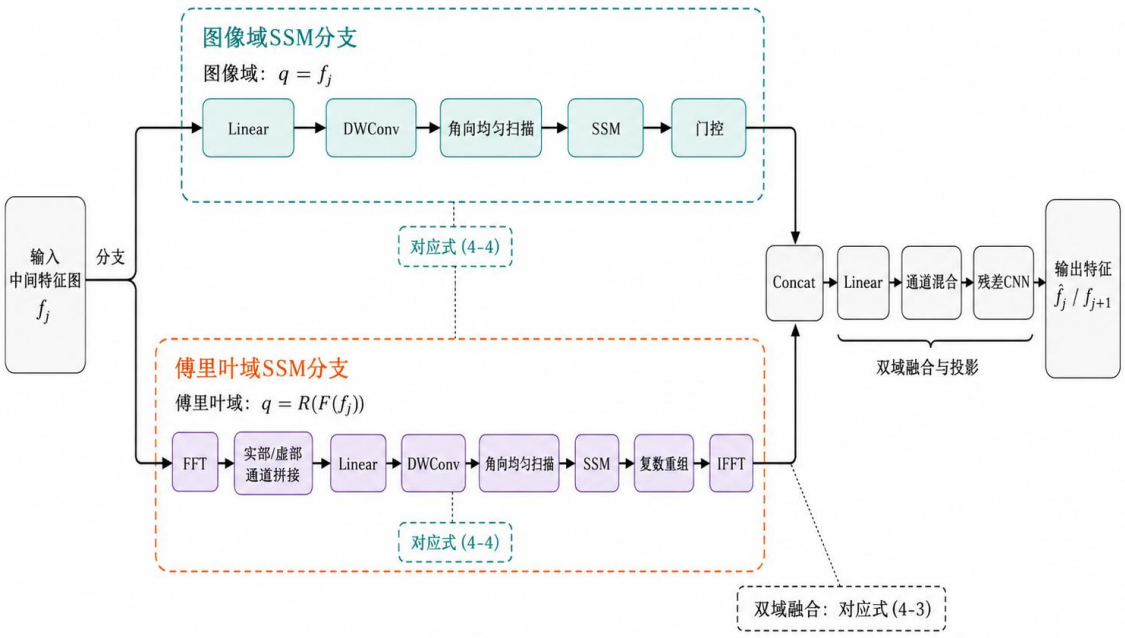


图 4-2　USR-Mamba 双域 SSM 模块结构

在每个分支内部，特征首先经过线性扩展和深度卷积，以增强局部感受能力；随后利用 SSM 模块建立长距离序列依赖；最终通过通道混合与卷积补充分支输出。其统一表达如式(4-4)所示。这里的门控分支用于调节状态空间输出的重要性，深度卷积用于提取局部空间邻域信息，通道混合卷积则用于增强不同语义通道之间的交互。由于图像恢复任务不仅依赖长距离关联，也依赖精细的局部结构表达，因此，局部卷积—序列建模—通道混合的组合更适用于超声超分辨率场景。三类操作依次衔接，在保持分辨率的同时兼顾局部响应与全局依赖。

完成双分支处理后，图像域特征和傅里叶域特征在通道维度进行拼接，并通过投影操作恢复到目标通道数。这样既能够保留两种特征的互补信息，避免单一域特征表达不足，也便于与后续残差 CNN 模块在通道规模和特征分布上保持衔接。总体而言，USR-Mamba 并非简单使用 SSM 替代 CNN，而是将 CNN、双域 SSM 和通道混合分别配置在不同功能层次中：编码器和解码器中的 CNN 负责稳定提取与恢复局部结构，瓶颈中的双域 SSM 负责补充长距离上下文和频谱上下文，通道混合则负责加强不同分支、不同通道之间的信息融合。该设计更符合超声图像中局部噪声显著、组织轮廓连续、散斑纹理具有统计相关性且频谱成分复杂的实际特点，有助于在超分辨率重建过程中兼顾细节恢复、结构连续性和计算效率。

4.2.2 基于残差 CNN 的空间细节优化方法

双域 SSM 模块能够增强网络对长距离上下文关系和频率分布的建模能力，但其本质仍属于序列建模结构。二维超声图像展开为一维序列后，部分局部空间邻接关系只能通过序列关系间接表示；若直接依赖 SSM 输出生成最终图像，组织边界、亮点响应和细粒度散斑纹理处可能出现过平滑、位置漂移或局部响应分散等问题。因此，本文在双域 SSM 模块之后引入残差 CNN 模块，使 SSM 负责长距离结构建模和频谱上下文表达，残差 CNN 负责局部边缘、亮点响应和细粒度纹理的补偿修正，具体更新形式见式(4-2)。

残差 CNN 模块通常由两级卷积、BN 和 ReLU 组成，并通过残差连接将输入特征与卷积修正项相加。其基本思想不是重新学习完整特征映射，而是学习相对于输入特征的增量修正。由此，双域 SSM 模块负责提供上下文表征，残差 CNN 则用于修正局部空间结构不够准确的部分，例如边界锐化、细纹理恢复和目标响应增强。残差 CNN 空间细节优化流程如图 4-3 所示。残差连接还为原始特征提供直接

传递路径，使局部卷积主要学习需要补偿的高频分量，降低深层变换对低频组织轮廓的无谓改写。由此，细节增强受到输入结构的约束，不易演变为脱离原图的统一锐化。

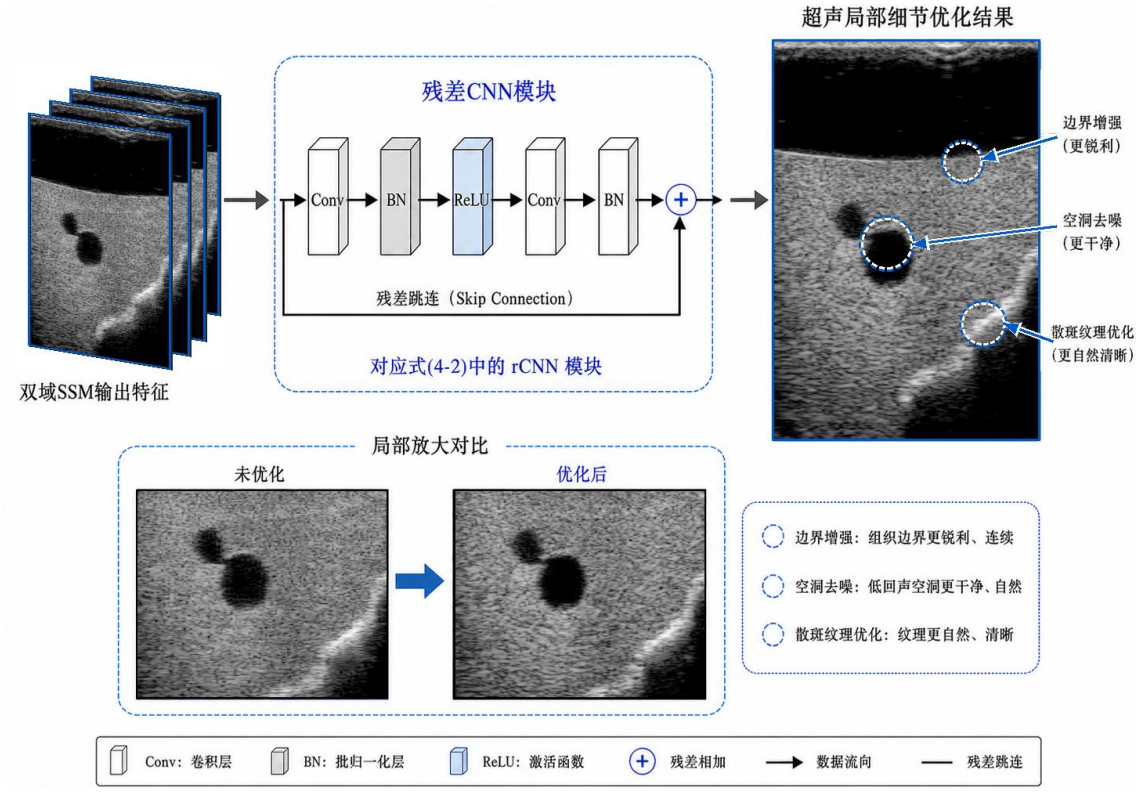


图 4-3　残差 CNN 空间细节优化流程

从超声图像成像特点看，残差 CNN 模块主要发挥以下三方面作用。第一，对于强回声边界，卷积核能够在局部邻域中提取灰度突变和方向性纹理，使重建图像中的组织轮廓更清晰，并增强边界两侧灰度过渡的可辨识性。第二，对于弱回声背景和阴影区域，残差结构不对所有高频分量进行无差别放大，而是根据双域 SSM 输出对局部不可靠纹理进行适度抑制，从而降低伪结构生成的概率，避免将背景散斑误增强为真实组织纹理。第三，对于亮点目标和细小结构，局部卷积能够补偿序列建模过程中可能产生的位置偏差，使目标响应更集中、边缘扩散更少，有利于提升空间分辨率相关指标，并改善亮点目标在重建图像中的空间响应质量。

残差 CNN 模块与第 3 章中基于结构先验的局部自适应处理在思想上具有一致性。第 3 章通过结构先验使复杂结构区域倾向于采用更精细的局部建模方式，平滑背景区域倾向于采用更稳定的整体建模方式，从而在去噪过程中平衡结构保持

与散斑抑制；本章则通过双域 SSM 与残差 CNN 的结合，使网络在复杂组织区域保留局部高频细节，在背景区域利用上下文关系抑制不可靠纹理。尽管两者实现手段不同，前者依赖显式块划分先验和多字典稀疏重建，后者依赖深度特征中的长距离建模与局部卷积修正，但目标都是提升超声图像增强结果的结构一致性、细节真实性和视觉稳定性。

残差 CNN 置于瓶颈阶段而非作为输出端锐化后处理，使局部修正参与后续解码，并避免同时放大噪声与真实边缘。由于瓶颈特征仍保持较高分辨率，该模块可在较精细尺度上优化边界、亮点和纹理。

4.2.3 基于角向均匀扫描的序列展开方法

视觉状态空间模型处理一维序列，二维特征需先展开。常规栅格或水平—垂直扫描偏向坐标轴方向，可能削弱对斜向、弧形和不规则结构的表达。USR-Mamba 采用角向均匀扫描，以图像中心为起点，按均匀角度和逐步增大的半径访问特征点，如图 4-4 所示。扫描路径由索引映射生成，状态更新后再按逆索引恢复二维位置，因此该过程只调整特征访问顺序，不引入插值或像素重采样。在角度和半径共同变化的访问过程中，相邻序列位置既包含局部邻域信息，也逐步引入不同方向的远距离特征。这种次序安排使后续状态更新能够在不增加序列长度的条件下均衡接收方向信息，并为逆索引还原后的二维特征保持明确的位置对应关系。

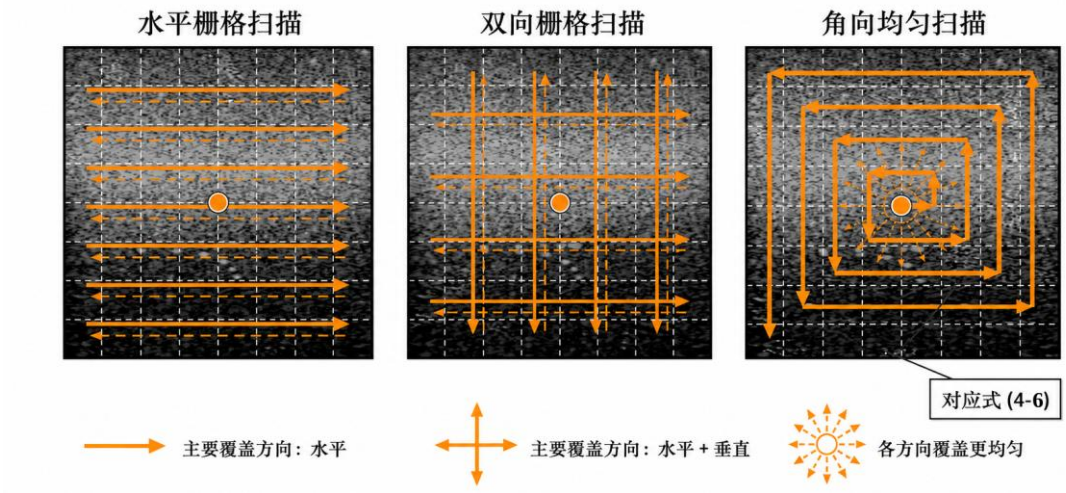


图 4-4　角向均匀扫描与传统扫描方式对比

具体而言，该方法从特征图中心区域出发，按照近似螺旋形路径逐步向外访问像素，使扫描序列能够在多个方向上较均匀地覆盖局部和远距离邻域。设扫描路径

为 $p(n)=\left(h[n],w[n]\right)$，则角向均匀扫描下的序列化、状态更新与二维还原过程可表示为：

$$\begin{cases} z_{\text{in}}[n,c]=e\left[p(n),c\right] \\ \ell[n,c]=\bar{A}\ell[n-1,c]+\bar{B}[n]z_{\text{in}}[n,c] \\ z_{\text{out}}[n,c]=\bar{C}[n]\ell[n,c] \\ M\left[p(n),c\right]=z_{\text{out}}[n,c] \end{cases} \tag{4-6}$$

其中，$n=1,2,\cdots,H\times W$ 表示序列索引，c 表示通道索引，$\ell[n,c]$ 表示隐藏状态，$\bar{A}$ 为状态转移参数，$\bar{B}[n]$ 和 $\bar{C}[n]$ 为输入相关参数，M 表示还原后的二维特征图。与式(4-4)中的 $\text{SSM}_{\theta}(\cdot)$ 对应，式(4-6)强调的是角向均匀扫描所定义的序列组织方式。

相比传统栅格扫描，角向均匀扫描不再长期沿单一坐标轴推进，而是在半径逐渐增大的同时持续改变访问方向。由此，中心位置附近的像素能够在较短的序列距离内覆盖周围多个方向的邻域，后续序列则逐步纳入更大范围的远距离上下文信息，从而兼顾局部邻域表达与长距离结构建模。对于图像域分支，这种扫描方式更有利于捕获不同方向上的组织边界、纹理延展与散斑分布；对于傅里叶域分支，则有助于在频谱平面上更均匀地聚合不同方向的频率信息，避免模型仅偏向某些固定方向的频谱响应。

角向均匀扫描并不会改变特征图中像素或特征点的数量，也不会引入类似全局自注意力的二次复杂度。其主要作用在于重新定义二维特征到一维序列的访问顺序，使 SSM 在相同序列长度下获得更均衡的方向感受能力。对于组织结构方向不确定、纹理分布不规则且散斑响应具有随机性的超声图像而言，该设计能够更好地适应该类成像特点。

综上，角向均匀扫描改善序列展开的方向均衡性，双域状态空间模块补充空间与频谱上下文，残差 CNN 负责局部细化。该组合兼具长距离建模、较低复杂度和局部结构恢复能力，更适合超声图像中方向不确定、散斑随机且频谱成分复杂的超分辨率任务。

4.3 数据集预处理与消融实验设计

本节说明 USR-Mamba 的数据构建、测试流程和消融方案。第 3 章的 Block K-SVD 作为前级处理，在保持局部结构的同时降低 32 线图像的部分散斑扰动；其输出作为 USR-Mamba 输入，形成结构先验去噪—状态空间超分辨率的串联流程。

本章用于输入 USR-Mamba 的 Block K-SVD 前级输出取块大小层数 $n=3$，取 $\{4,8,12\}$ 三种块大小，并未直接沿用第 3 章独立去噪评价中的 $n=6$ 设置。其原因在于，本章前级处理的目标不是单独追求最强的散斑平滑效果，而是为后级超分辨率网络提供噪声水平更稳定且局部结构仍然充分保留的 32 线输入。

若继续使用 16×16、20×20 和 24×24 等较大块，可能在进入 USR-Mamba 之前过早平滑弱边界、亮点响应和细粒度散斑纹理，降低后级网络恢复密集波束结构的可学习信息量。因此，$n=3$ 属于相对温和的结构先验去噪设置，用于在降低低波束线数图像噪声扰动的同时，尽可能保留后级网络需要进一步建模的高频细节。因此，前级参数选择以保留可学习细节为约束，而非沿用第 3 章独立去噪中覆盖全部尺度的设置。

该流程中，原生 32 波束线数基准图像是前级输入，Block K-SVD 32 线去噪图像是前级输出，同时也是后级输入；USR-Mamba 超分辨率图像是后级输出，原生 128 波束线数参考图像是后级参考。这样处理的目的不是将前级方法作为最终增强结果，而是先利用结构先验去噪降低低波束线数图像中的部分噪声扰动，再由后级网络学习从低波束线数图像到密集波束图像之间的非线性映射关系，从而在更稳定的输入基础上恢复接近原生高波束线数图像的纹理统计特征和局部结构响应。

4.3.1 数据集预处理

将 32 波束线数图像作为低波束线输入，对应 128 波束线数图像作为高波束线参考。训练使用成对图像学习两种成像条件之间的映射；测试时以 Block K-SVD 32 线去噪图像为输入，并与原生 128 线图像比较。

原始训练配对共 400 对，排除与测试集同源的 20 对后保留 380 对。每对图像生成 4 个裁切样本，裁切仅作用于左、右和底部 0～32 像素，随后以 Lanczos-3 恢复原尺寸；再结合确定性水平翻转，每轮训练等效使用 3040 个样本。该扩增用于增加结构变化覆盖并提高训练稳定性，不代表新增病例来源。后续可在更多病例、成像部位、探头参数和波束线条件下扩展数据，并分析样本规模对泛化能力的影响。

验证集包含 40 对图像，仅用于训练过程监控、超参数调整和模型选择，不参与梯度更新。测试集包含 20 张图像，按照主要结构类型划分为亮带、亮斑、亮点、空洞和沟壑 5 组，每组 4 张。该划分方式与前文对超声图像局部结构复杂度的分析相对应，能够分别考察模型在条带状强回声结构、点状或斑状强回声结构、局部低回声区域以及沟壑状纹理区域中的增强效果，从而更全面地评价模型对不同典

型超声结构的适应能力。同时，固定的分组比例保证验证集和测试集在各结构类型上采用一致的比较口径。

实验均采用离线静态超声 B 模式图像，在一致输入与参考条件下比较噪声抑制、结构保持、目标—背景对比和亮点空间响应。后续可接入实时成像系统或临床工作站，验证连续扫查、操作者差异、探头运动和参数变化下的稳定性。

4.3.2 消融实验设计

为分析 USR-Mamba 各结构的贡献，设置纯卷积瓶颈、无频域分支、无卷积精炼和栅格扫描 4 组消融实验，分别考察长距离建模、频谱建模、局部细化和序列展开路径的作用。

纯卷积瓶颈组将瓶颈阶段的状态空间模块替换为卷积残差块，用于评价长距离序列建模的贡献。若该组结果弱于完整模型，则说明仅依赖局部卷积难以充分表达远距离组织轮廓、阴影区域和散斑纹理之间的相关性，状态空间模块能够为低波束线数图像提供有效的全局上下文补充。

无频域分支组保留图像域状态空间分支，但移除傅里叶域分支，用于评价频谱上下文建模的作用。超声图像中的散斑纹理、组织边界和亮点目标不仅表现为空间域灰度变化，也对应一定频谱分布特征。若移除频域分支后指标下降，则说明频域分支能够从频率分布角度补充图像域特征，有助于纹理连续性、边界清晰度和结构稳定性恢复。

无卷积精炼组保留图像域和频域状态空间分支，但移除特征融合后的残差卷积精炼模块，用于评价局部卷积细化的贡献。状态空间模块侧重长距离上下文建模，卷积精炼模块更适合在局部邻域内修正组织边缘、亮点峰形和散斑细粒度纹理。该组可判断全局上下文聚合后是否仍需要局部空间优化。

栅格扫描组将角向均匀扫描替换为传统行优先栅格扫描，用于评价序列展开路径的影响。常规栅格扫描主要沿水平和垂直方向展开特征，可能使状态空间建模偏向坐标轴方向；而超声图像中的组织边界、弧形结构、阴影区域和亮点分布不一定与坐标轴一致。因此，该组用于分析角向均匀扫描对方向不确定结构建模能力的改善作用。四组消融的比较口径保持一致，均采用相同训练数据、优化配置和输入输出配对，仅改变目标模块或扫描路径，使指标差异能够对应到被考察结构。评价阶段还使用相同的指标计算程序和参考图像，避免处理链之外的差异干扰各模型之间的横向判断与作用归因。

4.4 评价指标与结果分析

本节从全局指标、亮点空间响应和消融实验三方面评价 USR-Mamba。鉴于超声散斑具有随机性，增强结果不要求与高波束线参考图像逐像素一致，因此主要采用 CNR、学习感知图像块相似度（Learned Perceptual Image Patch Similarity，LPIPS）和亮点组 FWHM-x，峰值信噪比（Peak Signal-to-Noise Ratio，PSNR）仅用于说明像素误差指标的局限。

4.4.1 评价指标

PSNR 由待评价图像与参考图像的均方误差计算，适合衡量逐像素灰度一致性。但超声超分辨率的合理输出允许散斑位置发生局部变化，只要组织结构与纹理统计保持可靠；因此，较高 PSNR 不必然对应更好的结构或感知质量。

基于上述特点，PSNR 不作为主要评价指标。过度追求逐像素一致可能压制合理散斑并导致平滑，而纹理统计更接近高波束线图像的结果也可能因散斑位置偏移获得较低 PSNR。后文仅用部分结果说明这一局限。

对比噪声比 CNR 已在第 3 章中介绍，本节不再重复其公式，而重点介绍本章实际使用的计算方式。本章的 CNR 并非直接在人工选取的单一区域上计算，而是基于第 2 章和第 3 章得到的块大小图自动生成目标区域、背景区域和噪声统计区域。具体而言，评价程序读取归一化后的块大小信息，并按照预设阈值划分三类区域：小块区域作为目标区域，中等块大小区域作为背景区域，小块至中等块大小区域作为噪声统计区域。随后，程序分别计算目标区域与背景区域的平均灰度差异，并使用噪声区域的灰度标准差作为归一化项，得到对应图像的 CNR。

该 CNR 计算方式具有两点优势：块大小图可近似区分边界、亮点等结构区域与平滑背景；目标、背景和噪声区域由统一规则自动生成，可减少人工选择带来的主观差异。

进一步采用 LPIPS 衡量增强结果与原生 128 线参考图像在深度特征空间中的差异。该指标先提取多层特征，再计算加权距离；数值越低，表示感知结构与纹理越接近参考图像。

LPIPS 能够弱化局部散斑位置偏移的影响，更关注组织边界、亮点形态、纹理颗粒感和整体结构。因此，本章将其作为主要全参考感知指标，与 CNR 共同评价对比关系和感知相似性。两者分别对应局部对比与整体感知差异，可避免仅依赖单一指标作出判断。

对于每个待评价结果，程序将灰度图转换为三通道图像，并归一化到 LPIPS 所需的输入范围后，使用 AlexNet 版本的 LPIPS 网络计算其与参考图像的特征距离。对于参考图像本身，LPIPS 不作为有效比较值；消融实验中，各消融组均与同一参考图像计算 LPIPS，从而保证不同结构变体之间的比较具有一致参考。

半高全宽 FWHM 已在第 3 章中介绍，本节不再重复其公式。本章只使用亮点组的水平半高全宽 FWHM-x，用于分析点状强回声目标在水平方向上的空间响应宽度。之所以不再展示亮带组 FWHM 和 FWHM-y，是因为亮带结构具有较强方向性，且部分亮带在水平方向贯穿感兴趣区域，FWHM-x 不具备稳定的区分意义；而 FWHM-y 容易受到目标形态、区域漂移和局部散斑分布影响。相比之下，亮点组 FWHM-x 更能反映低波束线到高波束线增强过程中点状目标横向展宽或收缩的变化，因此更适合作为本章空间响应分析的辅助指标。

4.4.2 结果分析

首先比较 Block K-SVD 32 线去噪图像、USR-Mamba 超分辨率图像和原生 128 线参考图像的全局平均指标，结果见表 4-1。

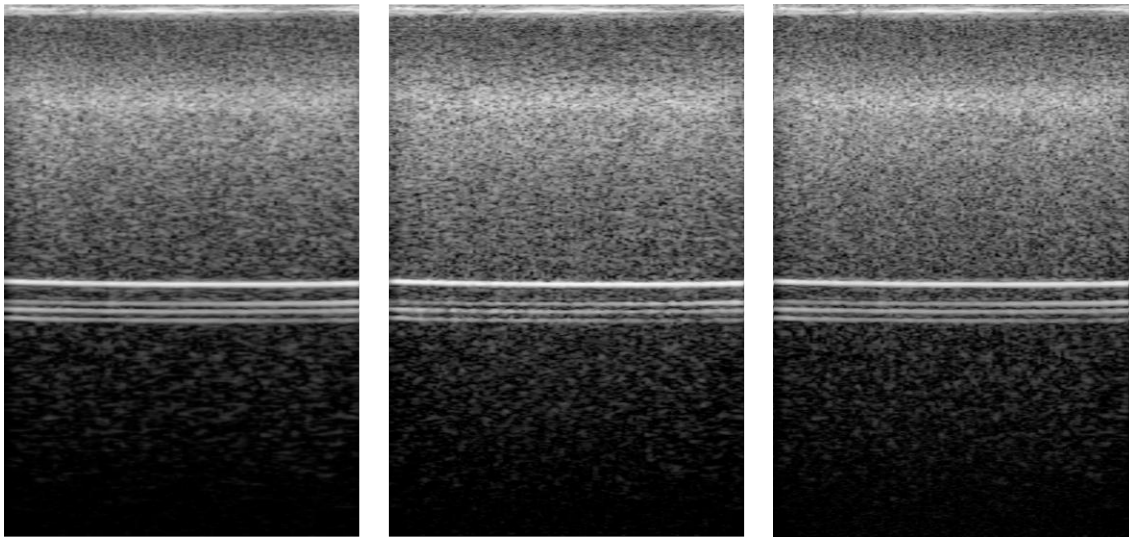
表 4-1 不同图像版本的全局平均增强评价指标

图像版本	CNR	LPIPS
Block K-SVD 32 线去噪图像	1.805809	0.180011
USR-Mamba 超分辨率图像	**1.824905**	**0.148138**
原生 128 波束线数参考图像	*1.833151*	*（不适用）*

由表 4-1 可见，USR-Mamba 超分辨率图像的 CNR 为 1.824905，高于 Block K-SVD 32 线去噪图像的 1.805809，并接近原生 128 波束线数参考图像的 1.833151。相对于后级输入，后级输出的 CNR 提高 0.019096，约提升 1.06%；与后级参考的 CNR 差距由 0.027342 减小至 0.008246，说明 USR-Mamba 在结构先验去噪基础上进一步增强了目标区域与背景区域之间的灰度对比和可分性。从指标变化可以看出，Block K-SVD 去噪后虽然已经在一定程度上抑制了 32 线图像中的背景散斑噪声，但其目标—背景对比关系仍与原生 128 波束线数图像存在差距；经过 USR-Mamba 超分辨率重建后，图像对比关系进一步向密集波束参考图像靠近。该结果表明，Block K-SVD 和 USR-Mamba 并不是相互替代的关系，而是前后级串联关系：前者用于提供噪声水平较低、结构边界相对稳定的低波束线输入，后者则在此基础上进一步学习密集波束图像中的组织结构、亮点响应和纹理分布特征。

从 LPIPS 指标看，Block K-SVD 32 线去噪图像的 LPIPS 为 0.180011，而 USR-Mamba 超分辨率图像降低至 0.148138，下降 0.031873，约降低 17.71%。LPIPS 的降低表明后级输出在深度感知特征空间中更接近原生 128 波束线数参考图像，即其整体视觉结构、纹理分布和局部细节表达均有所改善，同时说明 USR-Mamba 能够在超分辨率过程中进一步修正前级去噪图像中残留的结构偏差和纹理退化。与 CNR 主要反映目标区域和背景区域之间的可分性不同，LPIPS 更侧重从感知特征层面评价图像与参考图像之间的相似程度，能够补充反映整体结构一致性和视觉真实性。因此，结合 CNR 和 LPIPS 结果可以认为，USR-Mamba 不仅提高了局部结构与背景之间的对比关系，也使整体纹理特征、散斑统计特性和感知相似性向原生密集波束图像靠近，从而验证了双域 SSM 和残差 CNN 联合建模在超声超分辨率任务中的有效性。

为观察全局指标之外的结构与纹理差异，选取同一测试样本并列显示三种图像版本，结果见图 4-5。



Block K-SVD 32 线去噪图像　　USR-Mamba 超分辨率图像　　原生 128 波束线数参考图像

图 4-5　不同图像版本视觉对比

由图 4-5 可见，Block K-SVD 32 线去噪图像已经在一定程度上抑制低波束线数图像中的散斑扰动，但中部层状强回声结构的边界仍相对偏厚，暗背景区域中的散斑颗粒分布也与原生 128 波束线数参考图像存在一定差异。经过 USR-Mamba 超分辨率增强后，中部水平强回声带的边界连续性、层状结构分离程度和下方暗背景区域的纹理颗粒感均更接近原生 128 波束线数参考图像。结合表 4-1 可知，USR-

Mamba 超分辨率图像的 CNR 由 Block K-SVD 32 线去噪图像的 1.805809 提高至 1.824905，更接近原生 128 波束线数参考图像的 1.833151；LPIPS 由 0.180011 降低至 0.148138，表明后级输出在感知特征空间中更接近高波束线数参考图像。该结果说明，USR-Mamba 并非仅对 Block K-SVD 结果进行平滑或锐化处理，而是在前级结构先验去噪结果的基础上，进一步恢复低波束线条件下缺失的组织边界、局部纹理和散斑统计特征。医学超声图像中的散斑分布具有随机性，因此视觉对比不应要求增强图像与原生 128 波束线数参考图像在每个散斑位置上完全一致，而应重点关注整体纹理细节特征、主要结构形态和目标与背景对比关系是否向高波束线数图像靠近。

为进一步分析状态空间瓶颈、频谱建模、局部细化和扫描路径的作用，将完整模型与 4 个结构消融组进行比较，结果见表 4-2。

表 4-2　USR-Mamba 结构消融实验全局平均增强指标

结构消融模型	**CNR**	**LPIPS**
纯卷积瓶颈组	1.785676	0.169659
无频域分支组	1.799880	0.171038
无卷积精炼组	1.804256	0.165411
栅格扫描组	1.796211	0.160456
完整模型组	**1.824905**	**0.148138**
原生 128 线	*1.833151*	*（不适用）*

由表 4-2 可见，完整模型组的 CNR 高于纯卷积瓶颈组、无频域分支组、无卷积精炼组和栅格扫描组。与纯卷积瓶颈组相比，完整模型组的 CNR 提高 0.039229，约提升 2.20%，表明状态空间瓶颈能够补充卷积局部感受野不足的问题，使网络更优地利用远距离组织结构和散斑纹理之间的上下文关系。与无频域分支组相比，完整模型组的 CNR 提高 0.025025，约提升 1.39%，说明傅里叶域分支能够为图像域分支提供频谱结构信息，有助于增强目标区域和背景区域之间的统计区分度。与无卷积精炼组相比，完整模型组的 CNR 提高 0.020649，约提升 1.14%，说明状态空间特征融合后仍需要局部卷积精炼，以修正边缘、亮点响应和细粒度纹理。与栅格扫描组相比，完整模型组的 CNR 提高 0.028694，约提升 1.60%，说明角向均匀扫描在目标与背景对比保持方面优于传统行优先扫描。该趋势与各消融组的 LPIPS 差异方向一致，说明对比增强并非以牺牲感知相似性为代价。

从 LPIPS 指标看，完整模型组的 LPIPS 为 0.148138，低于纯卷积瓶颈组的 0.169659，表明完整模型组在感知特征层面最接近原生 128 波束线数参考图像。该结果与 CNR 指标基本一致，表明状态空间瓶颈、傅里叶域分支、融合后卷积精炼和角向均匀扫描均对增强结果具有贡献。其中，无频域分支组的 LPIPS 相对较高，表明仅依赖图像域状态空间建模时，网络对散斑纹理和组织边界对应的频谱结构表达仍不充分；无卷积精炼组虽然保留了双域 SSM，但 LPIPS 仍高于完整模型组，表明全局上下文聚合不能完全替代局部空间细节修正；栅格扫描组的 CNR 和 LPIPS 均弱于完整模型组，表明序列展开路径会影响 SSM 对方向不确定结构的建模效果。CNR 与 LPIPS 从对比关系和感知特征两个侧面给出一致趋势，说明完整模型的优势并非由单一指标的偶然波动造成。

为观察各模块对视觉结果的影响，将 4 个消融组、完整模型和原生 128 线参考图像并列显示，结果见图 4-6。

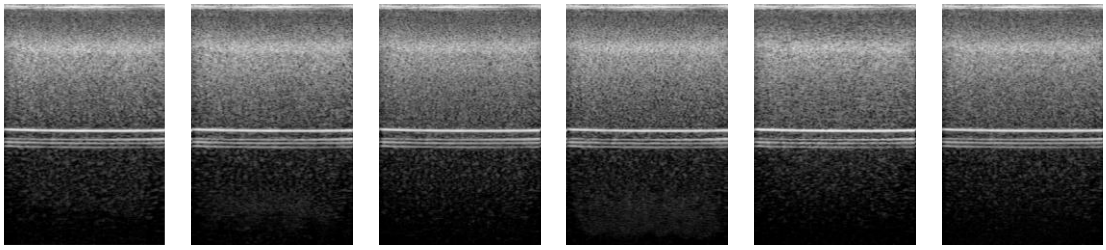


图 4-6　不同结构消融模型视觉对比

由图 4-6 可见，四个结构消融组均能够恢复图像中部主要层状强回声结构，说明各网络变体均具备一定的超分辨率重建能力，但在边界清晰度、纹理连续性和暗背景散斑分布方面仍存在明显差异。纯卷积瓶颈组主要依赖局部卷积操作，对远距离组织结构之间的关联表达不足，因而在层状结构连续性方面存在一定欠缺；无频域分支组缺少对频谱结构的显式约束，对高频纹理和整体谱分布的恢复能力相对有限；无卷积精炼组虽然保留了 SSM 长距离建模能力，但对局部边界、亮点响应和细粒度纹理的修正不足；栅格扫描组受固定坐标方向影响，对非轴向结构和斜向纹理的建模稳定性较弱。相比之下，USR-Mamba 完整模型能够综合利用图像域 SSM、傅里叶域 SSM、残差 CNN 和角向均匀扫描机制，在强回声带边界、暗背景散斑颗粒感和整体纹理连续性方面更接近原生 128 波束线数参考图像。结合表 4-2 可知，完整模型组 CNR 为 1.824905，高于四个消融组；LPIPS 为 0.148138，低于

四个消融组，表明各结构设计均对增强结果具有贡献，完整结构能够在目标—背景对比和感知相似性之间取得更优平衡。

为说明 PSNR 的局限，补充给出部分结果：Block K-SVD 32 线去噪图像的 PSNR 为 24.460818 dB，高于 USR-Mamba 的 22.352489 dB，4 个消融组也均高于完整模型。若仅依据 PSNR，会得出与 CNR、LPIPS 和 FWHM-x 不一致的判断，说明逐像素误差不能充分反映散斑统计、结构感知和空间响应。因此，PSNR 不列为主要评价指标。

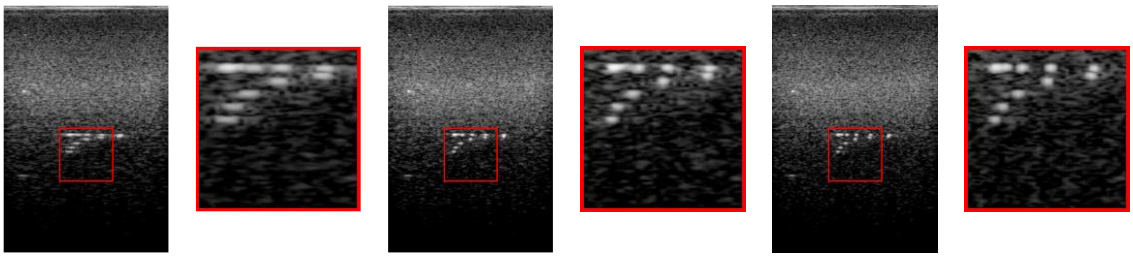
进一步采用亮点组 FWHM-x 评价点状强回声目标的水平响应宽度，以分析不同模型对亮点横向展宽、峰形集中程度及空间聚焦能力的影响；该指标越接近原生 128 波束线数参考图像，说明空间响应恢复越充分，结果见表 4-3。

表 4-3　不同图像版本亮点组平均 FWHM-x 结果

图像版本	**FWHM-x**
Block K-SVD 32 线去噪图像	40.938095
USR-Mamba 超分辨率图像	**19.834223**
原生 128 波束线数参考图像	*20.740545*

由表 4-3 可见，Block K-SVD 32 线去噪图像的亮点组 FWHM-x 为 40.938095，明显大于原生 128 波束线数参考图像的 20.740545，说明低波束线输入存在横向展宽。经 USR-Mamba 增强后，FWHM-x 降至 19.834223，较后级输入降低约 51.55%；与原生 128 参考图像的差距由 20.197550 减小至 0.906322，说明后级网络能够有效收缩亮点响应，使其横向空间响应更接近原生高波束线数图像。

选取亮点组典型感兴趣区域，对 Block K-SVD 32 线去噪图像、USR-Mamba 输出和原生 128 线参考图像进行局部放大，结果见图 4-7，用于比较目标横向展宽、峰形集中程度和周围散斑纹理。



Block K-SVD 32 线去噪图像　　USR-Mamba 超分辨率图像　　原生 128 波束线数参考图像

图 4-7　亮点组不同图像版本局部放大对比

图 4-7 显示，Block K-SVD 输出中的亮点轮廓仍偏宽，边缘向背景过渡较分散；USR-Mamba 增强后峰形更集中、横向扩散减弱，与原生 128 线参考更接近。该现象与表 4-3 的 FWHM-x 结果一致，表明网络改善的是亮点空间响应，而非简单提高亮度或统一锐化。进一步的二维剖面对比见图 4-8。FWHM-x 给出响应宽度的定量约束，局部图像与剖面则用于判断峰形变化是否伴随异常背景起伏，二者结合可减少仅依据单一宽度值作出判断的偏差。若峰宽接近参考值但峰顶形态或背景波动明显异常，仍不能据此认定空间响应已经得到充分恢复。

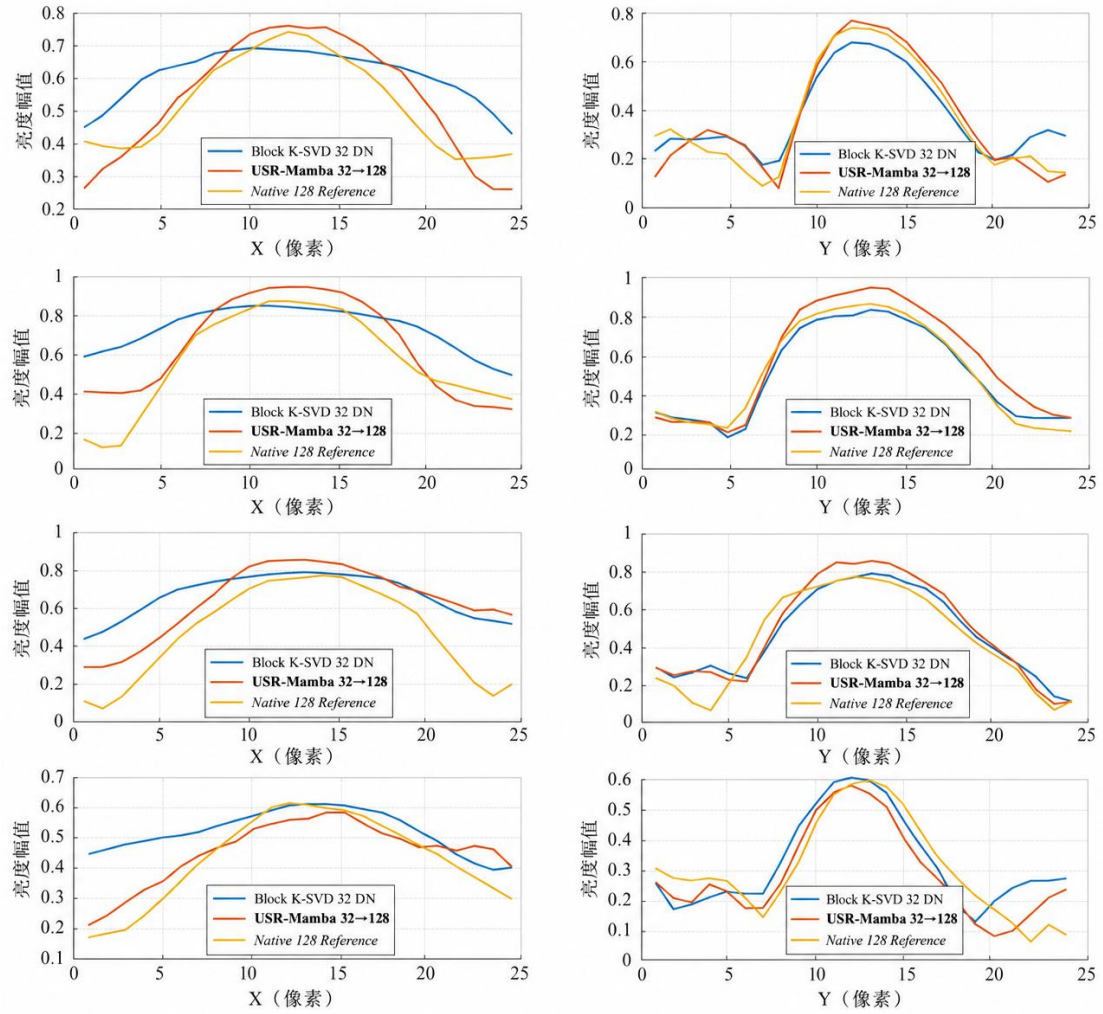


图 4-8　亮点组不同图像版本各 ROI 的 FWHM 测量剖面对比

由图 4-8 可见，Block K-SVD 32 线去噪图像在部分 ROI 中存在较明显的横向展宽，亮点峰形相较原生 128 波束线数参考图像更加平缓；而 USR-Mamba 32→128 超分辨率图像输出的峰形整体向原生 128 波束线数参考图像靠近，峰值位置和峰

宽均表现出更好的对应关系。该现象与表 4-3 中的平均 FWHM-x 结果一致，表明 USR-Mamba 能够在结构先验去噪结果基础上进一步收缩低波束线条件下被展宽的亮点响应，使点状强回声目标的水平空间响应更接近原生高波束线数图像。后级网络恢复的是参考峰形对应的空间响应，而非简单提高峰值。

为比较各结构模块对亮点空间响应的影响，统计消融模型的亮点组平均 FWHM-x，结果见表 4-4。

表 4-4　结构消融实验亮点组平均 FWHM-x 结果

结构消融模型	**FWHM-x**
纯卷积瓶颈组	18.144002
无频域分支组	18.015800
无卷积精炼组	15.993598
栅格扫描组	19.280794
完整模型组	**19.834223**
原生 128 线	*20.740545*

由表 4-4 可见，完整模型组的 FWHM-x 为 19.834223，与原生 128 波束线数参考图像的 20.740545 最为接近，差值为 0.906322，说明完整结构对亮点水平空间响应的恢复最为合理。纯卷积瓶颈组和无频域分支组的 FWHM-x 分别为 18.144002 和 18.015800，均低于完整模型组，说明缺少状态空间长距离建模或频域结构补充时，点状目标的水平响应容易出现偏窄现象。无卷积精炼组的 FWHM-x 为 15.993598，与参考图像差距最大，表明仅依赖双域 SSM 输出而缺少局部卷积精炼时，亮点峰形和局部边缘响应不够稳定。栅格扫描组的 FWHM-x 为 19.280794，虽然也接近参考图像，但仍弱于完整模型组，表明角向均匀扫描有助于进一步改善方向不确定亮点结构的空间响应恢复。因此，消融结果应结合相对参考图像的偏差与各感兴趣区域的剖面形态判断；FWHM-x 过小并不代表分辨率持续提高，也可能对应亮点响应过度收缩，不能将数值单向增减直接等同于质量提升。

平均 FWHM-x 反映整体响应宽度，但不能展示各感兴趣区域内的峰值高度、半高宽、边缘下降和背景起伏。为此，绘制各消融模型的二维亮度剖面对比，如图 4-9 所示。剖面比较采用相同 ROI 位置与归一化方式，因而可将峰形差异归因于模型结构，而非取样位置变化。统一尺度还便于对照峰顶、半高宽与边缘下降形态，使各曲线的幅值与形态差异具有直接可比性。

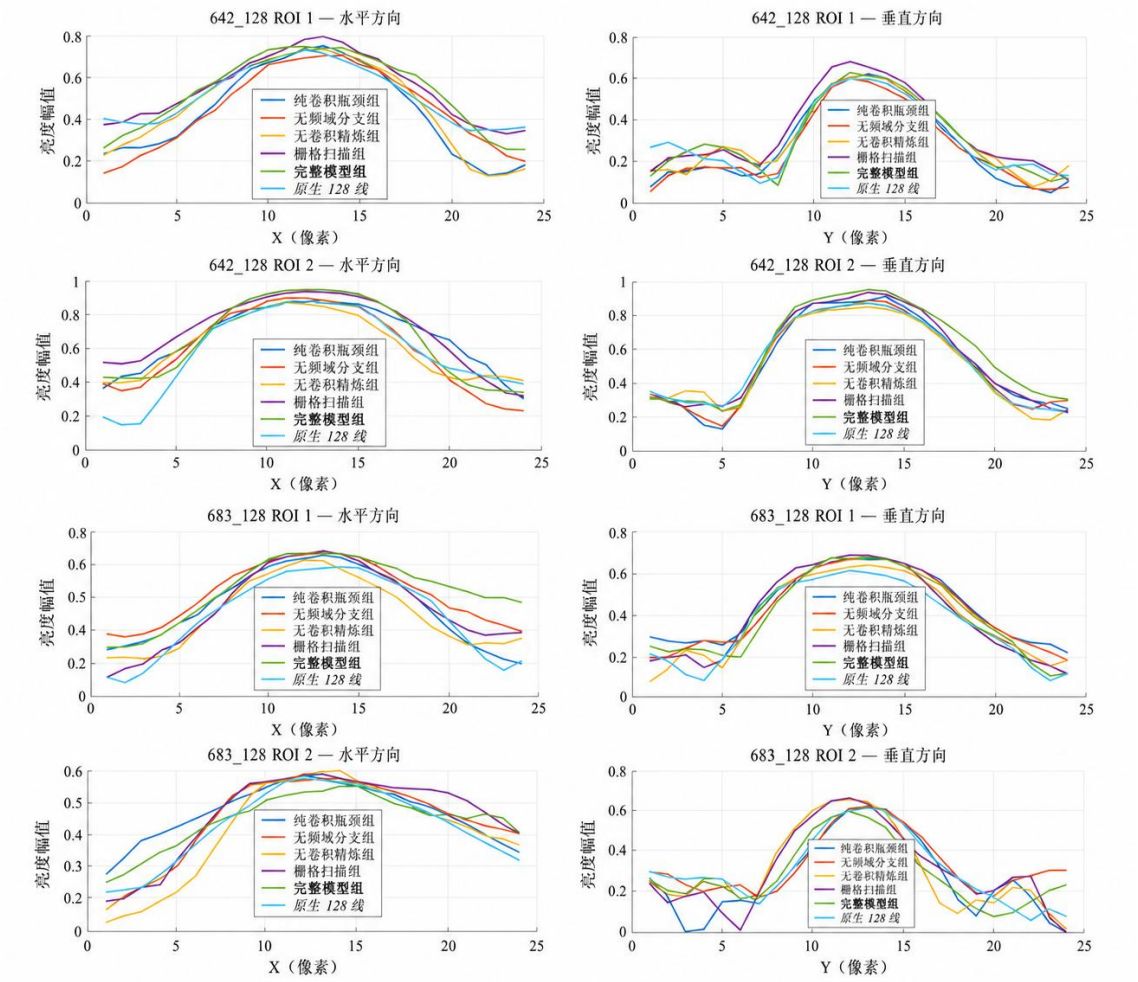


图 4-9　亮点组不同结构消融模型各 ROI 的 FWHM 测量剖面对比

由图 4-9 可见，不同消融模型在各 ROI 上的峰形变化并不完全一致，部分模型在某些亮点区域表现为峰宽偏窄，部分区域则出现峰值扩散或局部起伏不稳定现象，说明亮点空间响应并非由单一模块决定，而是与长距离上下文建模、频域结构表达、局部卷积精炼和序列扫描路径共同相关。结合表 4-4 可知，完整模型组在平均 FWHM-x 上最接近原生 128 波束线数参考图像，说明其能够在避免亮点过度展宽的同时，减少过度收缩造成的空间响应偏差。因此，完整 USR-Mamba 结构对点状目标水平空间响应的恢复更为合理。

综合上述结果，Block K-SVD 32 线去噪图像与 USR-Mamba 超分辨率图像构成的串联流程在目标—背景对比、感知相似性和亮点空间响应方面均得到改善。后级输出的 CNR 由 1.805809 提高至 1.824905，更接近原生 128 线参考图像的 1.833151；LPIPS 由 0.180011 降至 0.148138，说明组织结构与纹理的深层特征差异减小；亮

点组 FWHM-x 由 40.938095 降至 19.834223，与参考图像的 20.740545 接近。消融实验中，移除状态空间瓶颈、频域分支、卷积精炼或角向均匀扫描均会造成至少一项主要指标退化，说明各模块分别承担长距离建模、频谱补充、局部细化和方向均衡作用。PSNR 的排序与 CNR、LPIPS 及 FWHM-x 不一致，也进一步表明逐像素误差不适合作为本任务的主要评价依据。

4.5 本章小结

本章构建了面向医学超声 B 模式图像超分辨率的 USR-Mamba，并将其作为 Block K-SVD 自适应去噪之后的后级增强网络。网络采用编码器—高分辨率瓶颈—解码器结构：编码器提取低波束线图像中的灰度、散斑和边缘特征，高分辨率瓶颈在尽量保留弱小目标位置的条件下聚合上下文，解码器结合跳跃连接恢复组织边界和细粒度纹理。瓶颈中的图像域与傅里叶域状态空间分支分别建模空间结构和频谱分布，残差卷积补偿局部边缘与亮点细节，角向均匀扫描减弱规则栅格展开的方向偏置。由此，网络在控制长序列计算复杂度的同时，兼顾远距离组织关联、局部结构恢复和方向不确定结构的表达。

实验以 Block K-SVD 32 线去噪图像为输入、原生 128 线图像为参考，从全局指标、亮点空间响应和结构消融三个层面进行评价。完整模型将 CNR 由 1.805809 提高至 1.824905，向参考图像的 1.833151 靠近；LPIPS 由 0.180011 降至 0.148138，表明感知结构与纹理更接近参考图像；亮点组 FWHM-x 由 40.938095 降至 19.834223，与原生 128 线图像的 20.740545 接近，说明低波束线条件下点状强回声目标的横向展宽得到明显改善。局部图像和二维剖面进一步显示，增强后的亮点峰形更集中，边缘下降更接近参考图像，而非仅通过统一锐化提高亮度。消融结果表明，状态空间瓶颈、频域分支、卷积精炼和角向均匀扫描均对最终效果有贡献；其中不同模块对 CNR、LPIPS 和 FWHM-x 的影响并不完全相同，说明双域上下文建模、局部细化和扫描路径具有互补作用。这些结果针对当前离线静态数据和既定训练配置，说明所提串联流程在一致输入与参考条件下具有可行性，但不能直接替代跨设备和动态场景验证。实时连续扫查条件下，还需进一步考察探头运动、成像参数变化和连续帧纹理波动对增强稳定性的影响。

结　论

围绕医学超声图像中散斑噪声明显、组织边界模糊、弱小结构显示不足和低波束线空间分辨率受限等问题，论文构建了 HEVC 结构先验提取—Block K-SVD 自适应去噪—USR-Mamba 超分辨率的串联增强流程，以局部结构复杂度指导差异化去噪，再通过状态空间模型补充长距离上下文和频谱信息，兼顾背景抑噪、组织结构保持与亮点空间响应恢复。

在结构先验提取方面，针对原始 HEVC 编码器侧重压缩效率、对超声细微结构响应不足的问题，通过限制帧内预测模式、引入结构失真权重并动态调整量化清零阈值，使组织边界、亮点目标和高频纹理倾向于细分，平滑背景保留较大块。亮斑组实验中，感兴趣区域内变换单元平均大小由 6.332073 降至 4.600090，背景区域与感兴趣区域之比由 0.893995 升至 1.009070，说明改进后的块划分增强了结构区分能力，可为后续去噪尺度选择提供有效先验。

在自适应去噪方面，Block K-SVD 将 HEVC 块划分转换为像素级尺度图，并结合插值、灰度调节、离散聚类和多字典稀疏重建实施差异化处理，使平滑背景使用较大块抑制散斑，边缘、纹理和亮点区域使用较小块保持结构。其 CNR 和 ENL 较原始图像分别提高 2.36%和 4.83%；相较固定 8×8 分块方法，EPI 和 FSIM 分别提高 6.98%和 5.26%；较遍历 6 种固定块大小的总耗时缩短 18.72%，表明所提方法兼顾噪声抑制、结构保持与计算效率。

在超分辨率方面，USR-Mamba 以 Block K-SVD 32 线去噪图像为输入，结合空间—频率双域状态空间建模、残差卷积和角向均匀扫描，补充长距离组织关联、频谱结构、局部细节和方向不确定结构的表达。其 CNR 由 1.805809 升至 1.824905，接近原生 128 线参考图像的 1.833151；LPIPS 由 0.180011 降至 0.148138；亮点组 FWHM-x 由 40.938095 降至 19.834223，与参考图像的 20.740545 接近，说明目标—背景对比、感知相似性和亮点横向响应均得到改善。

总体上，所提串联流程在散斑抑制、结构保持、感知质量和空间响应恢复之间取得了较均衡的结果，验证了结构先验与长距离序列建模协同用于超声图像增强的可行性。现有验证仍基于离线静态图像，后续需在更大规模、多来源数据和实时连续扫查条件下检验训练稳定性、跨设备泛化能力、运行效率及临床应用可靠性。

参考文献

[1] Hussain S, Mubeen I, Ullah N, et al. Modern diagnostic imaging technique applications and risk factors in the medical field: A review[J]. BioMed Research International, 2022, 2022: 5164970.

[2] Avola D, Cinque L, Fagioli A, et al. Ultrasound medical imaging techniques[J]. ACM Computing Surveys, 2021, 54(3): 1-38.

[3] Sikhakhane K, Rimer S, Gololo M, et al. Evaluation of speckle noise reduction filters and machine learning algorithms for ultrasound images[J]. IEEE Access, 2024, 12: 81293-81312.

[4] Donoho D L. Compressed sensing[J]. IEEE Transactions on Information Theory, 2006, 52(4): 1289-1306.

[5] Candès E J, Romberg J, Tao T. Robust uncertainty principles: Exact signal reconstruction from highly incomplete frequency information[J]. IEEE Transactions on Information Theory, 2006, 52(2): 489-509.

[6] Aharon M, Elad M, Bruckstein A. K-SVD: An algorithm for designing overcomplete dictionaries for sparse representation[J]. IEEE Transactions on Signal Processing, 2006, 54(11): 4311-4322.

[7] Elad M, Aharon M. Image denoising via sparse and redundant representations over learned dictionaries[J]. IEEE Transactions on Image Processing, 2006, 15(12): 3736-3745.

[8] Nie D, Trullo R, Lian J, et al. Medical image synthesis with context-aware generative adversarial networks[C]. Medical Image Computing and Computer-Assisted Intervention (MICCAI), 2017: 417-425.

[9] Han X. MR-based synthetic CT generation using a deep convolutional neural network method[J]. Medical Physics, 2017, 44(4): 1408-1419.

[10] Chen J, Mei J, Li X, et al. TransUNet: Rethinking the U-Net architecture design for medical image segmentation through the lens of transformers[J]. Medical Image Analysis, 2024, 97: 103280.

[11] Gu A, Dao T. Mamba: Linear-time sequence modeling with selective state spaces[C]. Conference on Language Modeling (COLM), 2024.

[12] Zhu L, Liao B, Zhang Q, et al. Vision Mamba: Efficient visual representation learning with bidirectional state space model[C]. International Conference on Machine Learning (ICML), 2024: 62429-62442.

[13] Liu Y, Tian Y, Zhao Y, et al. VMamba: Visual state space model[C]. Advances in Neural Information Processing Systems, 2024, 37: 103031-103063.

[14] Ma J, Li F, Wang B. U-Mamba: Enhancing long-range dependency for biomedical image segmentation[EB/OL]. arXiv:2401.04722v1, 2024.

[15] Michailovich O V, Tannenbaum A. Despeckling of medical ultrasound images[J]. IEEE Transactions on Ultrasonics, Ferroelectrics, and Frequency Control, 2006, 53(1): 64-78.

[16] Deka B, Bora P K. Despeckling of medical ultrasound images using sparse representation[C]. Signal Processing and Communications (SPCOM), 2010.

[17] Reyes-Reyes R, Aranda-Bojorges G H, Garcia-Salgado B P, et al. Despeckling of ultrasound images using block matching and SVD in sparse representation[J]. Sensors, 2022, 22(14): 5113.

[18] Liang J, Cao J, Sun G, et al. SwinIR: Image restoration using Swin Transformer[C]. International Conference on Computer Vision Workshops (ICCVW), 2021: 1833-1844.

[19] Tamang L D, Kim B W. Super-resolution ultrasound imaging scheme based on a symmetric series convolutional neural network[J]. Sensors, 2022, 22(8): 3076.

[20] Brown K G, Waggener S C, Redfern A D, et al. Faster super-resolution ultrasound imaging with a deep learning model for tissue decluttering and contrast agent localization[J]. Biomedical Physics & Engineering Express, 2021, 7(6): 065035.

[21] ITU-T. Recommendation ITU-T H.265 (04/2013): High efficiency video coding[S]. Telecommunication Standardization Sector of ITU, 2013.

[22] Sullivan G J, Ohm J R, Han W J, et al. Overview of the High Efficiency Video Coding (HEVC) standard[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2012, 22(12): 1649-1668.

[23] Lainema J, Bossen F, Han W J, et al. Intra coding of the HEVC standard[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2012, 22(12): 1792-1801.

[24] Hannuksela M M, Lainema J, Vadakital V K M. The High Efficiency Image File Format standard [Standards in a Nutshell][J]. IEEE Signal Processing Magazine, 2015, 32(4): 150-156.

[25] Sullivan G J, Wiegand T. Rate-distortion optimization for video compression[J]. IEEE Signal Processing Magazine, 1998, 15(6): 74-90.

[26] Wiegand T, Schwarz H, Joch A, et al. Rate-constrained coder control and comparison of video coding standards[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2003, 13(7): 688-703.

[27] Pati Y C, Rezaiifar R, Krishnaprasad P S. Orthogonal matching pursuit: Recursive function approximation with applications to wavelet decomposition[C]. Asilomar Conference on Signals, Systems and Computers (ACSSC), 1993: 40-44.

[28] Tropp J A, Gilbert A C. Signal recovery from random measurements via orthogonal matching pursuit[J]. IEEE Transactions on Information Theory, 2007, 53(12): 4655-4666.

哈尔滨工业大学本科毕业论文（设计）
原创性声明与使用权限

本科毕业论文（设计）原创性声明

本人郑重声明：此处所提交的本科毕业论文（设计）《基于自适应压缩感知与状态空间模型的超声图像增强方法》，是本人在导师指导下，在哈尔滨工业大学攻读学士学位期间独立进行研究工作所取得的成果，且毕业论文（设计）中除已标注引用文献的部分外不包含他人完成或已发表的研究成果。对本毕业论文（设计）的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明。本毕业论文（设计）对使用 AI 工具的情况进行了明确标注。

作者签名：高浚博　日期：2026 年 6 月 8 日

本科毕业论文（设计）使用权限

本科毕业论文（设计）是本科生在哈尔滨工业大学攻读学士学位期间完成的成果，知识产权归属哈尔滨工业大学。本科毕业论文（设计）的使用权限如下：

（1）学校可以采用影印、缩印或其他复制手段保存本科生上交的毕业论文（设计），并向有关部门报送本科毕业论文（设计）；（2）根据需要，学校可以将本科毕业论文（设计）部分或全部内容编入有关数据库进行检索和提供相应阅览服务；（3）本科生毕业后发表与此毕业论文（设计）研究成果相关的学术论文和其他成果时，应征得导师同意，且第一署名单位为哈尔滨工业大学。

保密论文在保密期内遵守有关保密规定，解密后适用于此使用权限规定。

本人知悉本科毕业论文（设计）的使用权限，并将遵守有关规定。

作者签名：高浚博　日期：2026 年 6 月 8 日

导师签名：陈逸飞　日期：2026 年 6 月 8 日

致　谢

本科阶段的学习和毕业论文工作即将结束。回顾在哈尔滨工业大学的学习经历，从课程学习、科研训练到毕业论文撰写，各阶段均得到了师长、朋友和家人的支持与帮助。在此，谨向所有关心、指导和帮助过我的师长、同学、朋友和家人表示诚挚感谢。

感谢指导教师陈逸飞老师在毕业论文选题、研究思路、实验设计和论文写作过程中给予的指导与帮助。本文围绕超声图像增强展开研究，涉及 HEVC 块划分、自适应压缩感知去噪以及状态空间模型等内容。在研究推进过程中，老师对论文框架、方法设计和实验分析提出了许多具体建议，使我能够逐步理清问题逻辑，完善实验方案，并在反复修改中提高论文的完整性和规范性。老师严谨的治学态度和认真负责的工作作风，也使我在论文完成过程中受益良多。

感谢本科阶段陪伴我的朋友们。在课程学习、科研实践和论文写作期间，大家在学习讨论、资料查阅、实验调试和日常生活中给予了我许多帮助。与朋友们共同学习、交流和解决问题的经历，使我在面对复杂任务时能够保持耐心，也让我更加深切地体会到相互支持和共同成长的意义。

感谢我的家人长期以来的理解、支持与鼓励。大学四年中，无论是在学习选择、科研尝试还是毕业论文完成过程中，家人都给予了我持续而稳定的支持，使我能够更专注地完成学习任务。家人的信任与陪伴，为我完成本科阶段学习和毕业论文工作提供了重要支持。

感谢母校哈尔滨工业大学，感谢航天学院和自动化专业为我提供的学习平台和成长环境。在这里，我系统学习了专业知识，接受了工程训练和科研训练，也逐渐形成了更加严谨、踏实和负责的学习态度。本科阶段的经历将成为我今后继续学习和工作的重要基础。

在论文完成之际，向所有给予我帮助、支持和陪伴的人致以诚挚谢意。